



باسمه تعالی

دانشگاه صنعتی شریف

دانشکده مهندسی صنایع

پروژه درس مبانی داده‌کاوی و کاربرد آن

پیش‌بینی رضایت مسافران پرواز با استفاده از مدل‌های یادگیری ماشین

گروه ۵

اعضای گروه

شیده پرستاری فرکوش شماره دانشجویی: ۴۰۱۱۰۳۹۶۶

روزبه ملک احمدی شماره دانشجویی: ۴۰۱۱۰۴۴۶۸

استاد

سرکار خانم دکتر مریم بستان‌آرا

نیمسال دوم تحصیلی ۱۴۰۵-۱۴۰۴

فهرست

چکیده.....	۴
مقدمه.....	۴
جدول تقسیم کار.....	۵
۱. درک و شناخت داده.....	۶
۱.۱. متغیرها، نوع و محتوای آنها.....	۶
۲.۱. آمار توصیفی.....	۸
ستون‌های عددی پیوسته.....	۸
ستون‌های ترتیبی.....	۹
ستون‌های اسمی.....	۱۱
۳.۱. تحلیل بصری.....	۱۲
ستون‌های عددی.....	۱۲
ستون‌های ترتیبی.....	۱۶
ستون‌های اسمی.....	۱۹
ماتریس همبستگی و ارتباط میان متغیرها.....	۲۰
۲. پیش پردازش داده.....	۲۶
۱.۲. تمیزکاری اولیه.....	۲۶
حذف برخی ستون‌ها و بررسی یونیک بودن.....	۲۶
بررسی وجود رکوردهای مشابه.....	۲۶
بررسی محتوای ستون‌های دسته‌بندی.....	۲۶
۲.۲. مدیریت مقادیر گمشده.....	۲۷
روش اول: حذف سطرهای خالی.....	۲۷

۲۷	روش دوم: پر کردن مقادیر خالی با میانگین و میانه
۲۷	روش سوم: استفاده از ستون های مرتبط
۲۸	۳.۲. مدیریت داده های پرت
۳۰	رسیدگی به مقادیر غیرمنطقی و اشتباه
۳۰	۴.۲. نرمال سازی و استاندارد سازی
۳۱	۵.۲. بررسی تعادل کلاس ها
۳۳	۶.۲. انتخاب و مهندسی ویژگی ها
۳۴	مرحله ۰: جداسازی داده train و test
۳۴	مرحله ۱: حذف ویژگی های بدون ارزش و با واریانس صفر
۳۵	مرحله ۲: سنجش ارتباط هر ویژگی با متغیر هدف
۳۸	مرحله ۳: بررسی همبستگی و redundancy بین متغیرها
۳۹	مرحله ۴: بررسی اهمیت مبتنی بر مدل
۴۳	۷.۲. اعمال تمیزکاری روی داده تست
۴۴	روند کلی مدلسازی و ارزیابی و تحلیل نتایج
۴۵	۳. مدل سازی
۴۵	۱.۳. مدل Logistic Regression
۴۵	۱.۱.۳. ارزیابی با تمام متغیرها
۴۷	۲.۱.۳. ارزیابی بدون مدل های کاندید حذف
۴۸	۳.۱.۳. انتخاب مدل منتخب
۴۸	۴.۱.۳. Hyperparameters Tuning
۴۹	۲.۳. مدل Decision Tree
۴۹	۱.۲.۳. ارزیابی با تمام متغیرها
۵۰	۲.۲.۳. ارزیابی بدون مدل های کاندید حذف

۵۰	۳.۲.۳. انتخاب مدل منتخب
۵۱	۴.۲.۳. Hyperparameters Tuning
۵۱	۳.۳. مدل Random Forest
۵۱	۱.۳.۳. ارزیابی با تمام متغیرها
۵۲	۲.۳.۳. ارزیابی بدون مدل‌های کاندید حذف
۵۲	۳.۳.۳. انتخاب مدل منتخب
۵۳	۴.۳.۳. Hyperparameters Tuning
۵۳	۴.۳. مدل XGBoost
۵۳	۱.۴.۳. ارزیابی با تمام متغیرها
۵۴	۲.۴.۳. ارزیابی بدون مدل‌های کاندید حذف
۵۵	۳.۴.۳. انتخاب مدل منتخب
۵۵	۴.۴.۳. Hyperparameters Tuning
۵۶	۴. ارزیابی و تحلیل نتایج
۵۶	۱.۴. مقایسه و انتخاب مدل نهایی
۵۸	۲.۴. اجرای مدل روی داده test
۵۸	۳.۴. محاسبه معیارها و ارزیابی نتایج

چکیده

پژوهش حاضر با هدف پیش‌بینی رضایت مسافران یک شرکت هواپیمایی بر اساس داده‌های نظرسنجی انجام شده است. این مطالعه شامل ۱۰۳,۹۰۴ رکورد و ۲۵ متغیر است که ۱۴ متغیر آن مربوط به امتیازدهی مسافران به خدمات مختلف پروازی و مابقی شامل مشخصات مسافر و ویژگی‌های سفر می‌باشد. پس از شناسایی متغیرها و تحلیل توصیفی و بصری داده‌ها، مراحل پیش‌پردازش شامل مدیریت مقادیر گم‌شده، مدیریت داده‌های پرت و استانداردسازی متغیرها انجام شد. سپس با استفاده از ترکیب آزمون‌های آماری، ویژگی‌های کاندید حذف شناسایی شده و عملکرد مدل‌ها در دو حالت با تمام ویژگی‌ها و بدون آن‌ها مقایسه گردید. چهار الگوریتم Logistic Regression، Decision Tree، Random Forest و XGBoost بر روی داده‌ها پیاده‌سازی و با Crossvalidation ارزیابی شدند. مدل XGBoost با Accuracy 95.2% و ROC-AUC 98.9% بهترین عملکرد را نشان داد. نتایج نهایی نشان داد که متغیرهای Inflight wifi، Online boarding، Type of Travel و service به ترتیب مهم‌ترین عوامل پیش‌بینی‌کننده رضایت مسافران هستند، در حالی که متغیرهایی نظیر Gender و Gate Location تاثیر ناچیزی بر رضایت نهایی دارند.

مقدمه


امروزه صنعت هوانوردی با رقابت فزاینده‌ای روبرو است و شرکت‌های هواپیمایی برای جذب و حفظ مشتریان خود ناچار به بهبود مستمر کیفیت خدمات می‌باشند. یکی از موثرترین راه‌ها برای شناسایی نقاط قوت و ضعف خدمات، تحلیل نظرسنجی‌های انجام‌شده از مسافران است. داده‌کاوی با ارائه روش‌های آماری و یادگیری ماشین، امکان استخراج الگوهای پنهان و شناسایی عوامل کلیدی مؤثر بر رضایت مشتریان را فراهم می‌کند.

در این پروژه، داده‌های نظرسنجی یک شرکت هواپیمایی شامل امتیازات مسافران به ۱۴ شاخص خدماتی، مشخصات فردی و ویژگی‌های پرواز مورد بررسی قرار گرفته است. متغیر هدف، میزان رضایت نهایی مسافر در دو کلاس «رضایت‌مند» و «خشنی یا ناراضی» می‌باشد. هدف اصلی این مطالعه، ساخت یک مدل دقیق برای پیش‌بینی رضایت مسافران و شناسایی مهم‌ترین عوامل تعیین‌کننده آن است. برای این منظور، پس از انجام مراحل پیش‌پردازش و انتخاب ویژگی، چهار مدل طبقه‌بندی شامل رگرسیون لجستیک، درخت تصمیم، Random Forest و XGBoost پیاده‌سازی شده و عملکرد آن‌ها با یکدیگر مقایسه می‌گردد.

جدول تقسیم کار

به دلیل فشردگی زمانی در طول انجام پروژه، در بخش‌هایی تقسیم کار بر اساس برنامه زمانی اعضای گروه انجام می‌شد.

بخش	کار انجام شده	فرد انجام دهنده
۱. درک و شناخت داده	آمار توصیفی (میانگین، میانه، چارک ها و ...)	شیده پرستاری
۱. درک و شناخت داده	تحلیل بصری (هیستوگرام، همبستگی و ...)	شیده پرستاری
۱. درک و شناخت داده	شناسایی مشکلات موجود در داده (مقدار مقادیر گمشده و مقادیر پرت و غیر قابل قبول ، نویزدار و نامعتبر)	شیده پرستاری
۲. پیش پردازش داده	مدیریت مقادیر گمشده	روزبه ملک احمدی
۲. پیش پردازش داده	استانداردسازی	روزبه ملک احمدی
۲. پیش پردازش داده	انتخاب و مهندسی ویژگی ها	شیده پرستاری
۲. پیش پردازش داده	مدیریت داده های پرت	روزبه ملک احمدی
۲. پیش پردازش داده	بررسی تعادل کلاس ها	شیده پرستاری
۲. پیش پردازش داده	مدیریت دیتاست تست	روزبه ملک احمدی
۳. مدل سازی	Logistic Regression	شیده پرستاری
۳. مدل سازی	Decision Tree	روزبه ملک احمدی
۳. مدل سازی	Random Forest	روزبه ملک احمدی
۳. مدل سازی	XGBoost	شیده پرستاری
۴. ارزیابی و تحلیل نتایج	مقایسه و انتخاب مدل نهایی	شیده پرستاری
۴. ارزیابی و تحلیل نتایج	اجرای مدل روی داده تست	شیده پرستاری
۴. ارزیابی و تحلیل نتایج	محاسبه معیارها و ارزیابی نتایج	شیده پرستاری
ویراستاری گزارش	-	شیده پرستاری



۱. درک و شناخت داده

۱.۱. متغیرها، نوع و محتوای آنها

اولین قدم شروع کار شناخت ستون‌های دیتافریم موجود است. در ادامه، محتوای تمامی ستون‌های دیتافریم به منظور آشنایی اولیه آورده شده است:

- **Unnamed: 0**: شاخص یا ردیف خودکار سیستم است.
- **id**: کد شناسایی منحصر به فرد برای هر مسافر است تا اطلاعات هر فرد تفکیک شود.
- **Gender**: جنسیت مسافر را نشان می‌دهد (زن یا مرد).
- **Customer Type**: نوع وفاداری مشتری را مشخص می‌کند (مثلاً مشتری دائمی و وفادار یا مشتری عبوری/موقتی).
- **Age**: سن مسافر را بر حسب سال نشان می‌دهد.
- **Type of Travel**: هدف مسافر از سفر را مشخص می‌کند (سفر کاری یا سفر شخصی).
- **Class**: نوع صندلی و کلاس پروازی مسافر را نشان می‌دهد (مثل اکونومی، اکونومی پلاس یا بیزینس).
- **Flight Distance**: مسافت طی شده در پرواز را بر حسب مایل یا کیلومتر نشان می‌دهد.
- **Inflight wifi service**: میزان رضایت مسافر از کیفیت اینترنت وای فای داخل هواپیما را نشان می‌دهد.
- **Departure/Arrival time convenient**: میزان رضایت مسافر از مناسب و راحت بودن زمان حرکت و فرود پرواز.
- **Ease of Online booking**: میزان رضایت از سهولت و سادگی فرآیند رزرو آنلاین بلیط.
- **Gate location**: میزان رضایت مسافر از موقعیت و دسترسی به گیت خروجی در فرودگاه.
- **Food and drink**: میزان رضایت مسافر از کیفیت و تنوع غذا و نوشیدنی سرو شده در پرواز.

- **Online boarding**: میزان رضایت از فرآیند دریافت آنلاین کارت پرواز (بدون نیاز به صف فرودگاه).
- **Seat comfort**: میزان رضایت مسافر از راحتی و فضای صندلی هواپیما.
- **Inflight entertainment**: میزان رضایت از سیستم سرگرمی داخل پرواز (مانند مانیتور صندلی، فیلم‌ها و سایر امکانات).
- **On-board service**: میزان رضایت از خدمات کلی که خدمه پرواز در طول سفر ارائه داده‌اند.
- **Leg room service**: میزان رضایت مسافر از فضای جلوی پا مسافر و باز بودن بین صندلی‌ها.
- **Baggage handling**: میزان رضایت از فرآیند جابه‌جایی، تحویل و سلامت چمدان‌ها و بار مسافر.
- **Checkin service**: میزان رضایت از سرعت و نحوه برخورد کارکنان فرودگاه در بخش پذیرش و تحویل بار اولیه.
- **Inflight service**: میزان رضایت از کیفیت کلی پذیرایی و خدمات پرسنل پرواز در طول مدت حضور در هواپیما.
- **Cleanliness**: میزان رضایت مسافر از نظافت و تمیزی کلی بخش‌های مختلف هواپیما.
- **Departure Delay in Minutes**: میزان تاخیر هواپیما در زمان بلند شدن از فرودگاه مبدا به دقیقه.
- **Arrival Delay in Minutes**: میزان تاخیر هواپیما در زمان نشستن در فرودگاه مقصد به دقیقه.
- **satisfaction**: متغیر هدف نظرسنجی است که نشان می‌دهد مسافر در نهایت از پرواز خود راضی بوده یا حسی خنثی/ناراضی داشته است.

بعد از این، درستی تایپ هر ستون با توجه به ماهیت آن بررسی شد. در این دیتاست، تعداد قابل توجهی ستون وجود داشتند که در واقع امتیازدهی مسافران به خدمات مختلف بود. ستون‌های **Inflight wifi service**، **Food and drink**، **Gate location**، **Ease of Online booking**، **Departure/Arrival time convenient**، **Leg room service**، **On-board service**، **Inflight entertainment**، **Seat comfort**، **Online boarding**، **Baggage handling**، **Checkin service**، **Inflight service** و **Cleanliness** در دیتافریم با نوع داده **int64** ذخیره شده‌اند، اما از نظر ماهیت داده، این ستون‌ها **ordinal** هستند. به این معنا که مقادیر آن‌ها اعدادی مانند صفر تا پنج نیستند که بتوان روی آن‌ها عملیات ریاضی معنادار مانند جمع و میانگین‌گیری مستقیم انجام داد،

بلکه هر عدد نشان‌دهنده سطحی از رضایت مسافر است. ذخیره شدن این ستون‌ها به صورت int64 از نظر فنی مشکلی ایجاد نمی‌کند، اما باید در نظر داشت که این نوع داده صرفاً برای سهولت ذخیره‌سازی است و در مراحل بعدی، مخصوصاً هنگام مدل‌سازی یا تحلیل آماری، باید با این ستون‌ها به عنوان داده ordinal رفتار شود، نه داده عددی.

۲.۱. آمار توصیفی

ستون‌های عددی پیوسته^۱

روی چهار ستون عددی پیوسته یعنی Age، Flight Distance، Departure Delay in Minutes و Arrival Delay in Minutes پارامترهای مربوط به آن‌ها محاسبه می‌شود، چون این ستون‌ها برخلاف ستون‌های ترتیبی، مقادیر پیوسته و قابل جمع و میانگین‌گیری دارند. ابتدا با استفاده از تابع describe میانگین، میانه، انحراف معیار، حداقل، حداکثر و چارک‌ها برای هر یک از این ستون‌ها به دست می‌آید. سپس مقدار چولگی^۲ نیز برای هر ستون محاسبه می‌شود.

	Mean	Median	Std Dev	Min	Q1 (25%)	Q3 (75%)	Max	Skewness
Age	39.38	40.00	15.11	7.00	27.00	51.00	85.00	-0.00
Flight Distance	1189.45	843.00	997.15	31.00	414.00	1743.00	4983.00	1.11
Departure Delay in Minutes	14.82	0.00	38.23	0.00	0.00	12.00	1592.00	6.73
Arrival Delay in Minutes	15.18	0.00	38.70	0.00	0.00	13.00	1584.00	6.60

«جدول ۱»

جدول ۱ نشان می‌دهد که این متغیرها از نظر پراکندگی و شکل توزیع تفاوت‌های قابل توجهی دارند. بررسی شاخص‌های Mean، Median، Std Dev و Skewness برای این متغیرها انجام شده است.

متغیر Age با میانگین ۳۹.۳۸ و میانه ۴۰ دارای توزیعی تقریباً متقارن است که مقدار Skewness نزدیک به صفر نیز این موضوع را تایید می‌کند. همچنین انحراف معیار ۱۵.۱۱ و دامنه تغییرات ۷ تا ۸۵ سال نشان می‌دهد که افراد حاضر در داده‌ها از گروه‌های سنی متنوعی هستند.

برای Flight Distance، میانگین (۱۱۸۹.۴۵) به‌طور محسوسی بیشتر از میانه (۸۴۳) است و مقدار Skewness برابر با ۱.۱۱ نشان‌دهنده چولگی مثبت این متغیر است. همچنین انحراف معیار بالا و دامنه گسترده مقادیر بیانگر تنوع زیاد در مسافت پروازها است.

^۱ Numeric Continuous

^۲ Skewness

در هر دو متغیر *Departure Delay in Minutes* و *Arrival Delay in Minutes*، میانه برابر صفر دقیقه است، در حالی که میانگین حدود ۱۵ دقیقه است. این اختلاف، همراه با مقادیر بسیار بالای *Skewness* (بیش از ۶)، نشان می‌دهد که بیشتر پروازها بدون تاخیر یا با تاخیر اندک انجام شده‌اند، اما تعداد محدودی تاخیرهای بسیار طولانی داشته‌اند که باعث افزایش میانگین و ایجاد مقادیر پرت شده است که در مراحل بعدی بررسی می‌شوند. در مجموع، *Age* دارای توزیعی تقریباً متقارن است، *Flight Distance* چولگی مثبت کمی دارد و دو متغیر مربوط به تاخیر دارای چولگی مثبت شدید و مقادیر پرت هستند؛ بنابراین، این ویژگی‌ها باید در مراحل بعدی تحلیل و مدل‌سازی مورد توجه قرار گیرند. همچنین در بخش تحلیل بصری نیز به توزیع داده‌های این بخش به شکل جزئی تر پرداخته خواهد شد.

ستون‌های ترتیبی^۳

در این بخش برای چهارده ستون *ordinal* رضایت مسافران، به‌جای استفاده از میانگین و انحراف معیار، از معیارهای مناسب داده‌های ترتیبی استفاده می‌شود. ابتدا برای هر ستون مد یا پرتکرارترین امتیاز، میانه و همچنین میانگین محاسبه می‌شود، با این تفاوت که میانگین به‌عنوان یک برآورد تقریبی و نه یک شاخص دقیق مرکزی در نظر می‌شود.

بعد از آن یک جدول فراوانی ساخته می‌شود که در آن درصد هر امتیاز از صفر تا پنج برای هر ستون به‌طور جداگانه نمایش داده می‌شود تا توزیع دقیق پاسخ‌ها مشخص شود. رسم نمودارهای میله‌ای برای درک بهتر از این بخش بسیار موثر است که در قسمت بعدی (تحلیل بصری) انجام شده است.

	Mode	Median	Mean (rough avg)
Inflight wifi service	3	3.00	2.73
Departure/Arrival time convenient	4	3.00	3.06
Ease of Online booking	3	3.00	2.76
Gate location	3	3.00	2.98
Food and drink	4	3.00	3.20
Online boarding	4	3.00	3.25
Seat comfort	4	4.00	3.44
Inflight entertainment	4	4.00	3.36
On-board service	4	4.00	3.38
Leg room service	4	4.00	3.35
Baggage handling	4	4.00	3.63
Checkin service	4	3.00	3.30
Inflight service	4	4.00	3.64
Cleanliness	4	3.00	3.29

«جدول ۲»

³ Ordinal

نتایج جدول ۲ نشان می‌دهد که اغلب متغیرهای ترتیبی دارای Mode برابر با ۴ هستند که بیانگر آن است که رایج‌ترین امتیاز اختصاص یافته توسط مسافران، امتیاز نسبتاً مطلوب ۴ بوده است. همچنین Median بیشتر متغیرها برابر با ۳ یا ۴ است که نشان می‌دهد ارزیابی کلی مسافران در سطح متوسط تا خوب قرار دارد. از نظر Mean، بیشترین میانگین مربوط به Inflight service، Baggage handling و Seat comfort است که نشان‌دهنده رضایت بیشتر مسافران از این خدمات است. در مقابل، Ease of Inflight wifi service، Gate location و Online booking کمترین میانگین را دارند که بیانگر رضایت کمتر مسافران از این بخش‌ها است. به طور کلی، نتایج نشان می‌دهد خدمات ارائه شده در داخل پرواز نسبت به برخی خدمات قبل از پرواز، مانند اینترنت و رزرو آنلاین، ارزیابی مطلوب‌تری از سوی مسافران دریافت کرده‌اند.

	Inflight wifi	Departure /Arrival	Ease of Online	Gate location	Food and drink	Online boarding	Seat comfort	Inflight entertain	On-board service	Leg room service	Baggage handling	Checkin service	Inflight service	Cleanline ss
0	3.0	5.1	4.3	0.0	0.1	2.3	0.0	0.0	0.0	0.5	nan	0.0	0.0	0.0
1	17.2	14.9	16.9	16.9	12.4	10.3	11.6	12.0	11.4	10.0	7.0	12.4	6.8	12.8
2	24.9	16.5	23.1	18.7	21.2	16.8	14.3	17.0	14.1	18.8	11.1	12.4	11.0	15.5
3	24.9	17.3	23.5	27.5	21.5	21.0	18.0	18.4	22.0	19.3	19.9	27.4	19.5	23.7
4	19.1	24.6	18.8	23.5	23.4	29.6	30.6	28.3	29.7	27.7	36.0	28.0	36.5	26.2
5	11.0	21.6	13.3	13.4	21.5	19.9	25.5	24.3	22.8	23.7	26.1	19.8	26.1	21.8

«جدول ۳»

توزیع فراوانی امتیازها در جدول ۳ نشان می‌دهد که در اکثر متغیرها، بیشترین سهم پاسخ‌ها مربوط به امتیازهای ۳، ۴ و ۵ است که بیانگر ارزیابی نسبتاً مثبت مسافران از کیفیت خدمات است. متغیرهای Inflight service و Baggage handling بیشترین درصد امتیازهای ۴ و ۵ را به خود اختصاص داده‌اند و این موضوع با میانگین بالای آن‌ها نیز همخوانی دارد. در مقابل، در متغیرهای Inflight wifi service و Ease of Online booking سهم امتیازهای پایین‌تر (۱ و ۲) نسبتاً بیشتر است که نشان‌دهنده وجود نارضایتی بیشتر در این بخش‌ها است. همچنین مشاهده می‌شود که امتیاز صفر تنها در تعداد محدودی از متغیرها ثبت شده و فراوانی آن بسیار ناچیز است؛ بنابراین، به طور کلی می‌توان نتیجه گرفت که اکثر خدمات ارائه شده توسط شرکت هواپیمایی از دیدگاه

مسافران در سطح متوسط تا مطلوب ارزیابی شده‌اند، هرچند برخی خدمات مرتبط با امکانات آنلاین و اینترنت همچنان نیازمند بهبود هستند.

ستون‌های اسمی^۴

برای ستون‌های این بخش یعنی Gender، Customer Type، Type of Travel، Class و satisfaction که ترتیبی بین مقادیرشان وجود ندارد، از میانگین، میانه یا انحراف معیار استفاده نمی‌شود، چون این متغیرها برای داده‌های دسته‌ای بدون ترتیب بی‌معنا هستند. به‌جای آن، برای هر ستون تعداد و درصد هر دسته محاسبه می‌شود و پرتکرارترین گروه یا مد نیز مشخص می‌شود. این اطلاعات در قالب جدول برای هر ستون به‌طور جداگانه نمایش داده می‌شود و تحلیل اولیه‌ای از آن‌ها نیز آورده شده است.

- جنسیت: بررسی توزیع متغیر Gender نشان می‌دهد که تعداد افراد Female برابر با ۵۲,۷۲۷ نفر (۵۰.۷۵٪) و تعداد Male برابر با ۵۱,۱۷۷ نفر (۴۹.۲۵٪) است. اختلاف اندک میان دو گروه نشان می‌دهد که توزیع جنسیتی در مجموعه داده تقریباً متعادل بوده و هیچ‌یک از دو گروه بر دیگری برتری عددی قابل توجهی ندارد.
- نوع مسافر: نتایج مربوط به متغیر Customer Type نشان می‌دهد که بخش عمده مسافران را Loyal Customer با ۸۴,۹۲۳ نفر (۸۱.۷۳٪) تشکیل می‌دهند، در حالی که disloyal Customer تنها ۱۸.۲۷٪ از داده‌ها را شامل می‌شود. این توزیع بیانگر آن است که بیشتر مشتریان این مجموعه داده، مشتریان وفادار شرکت هواپیمایی هستند.
- نوع سفر: در متغیر Type of Travel، بیشترین فراوانی مربوط به Business travel با ۷۱,۶۵۵ نفر (۶۸.۹۶٪) است، در حالی که Personal Travel با ۳۲,۲۴۹ نفر (۳۱.۰۴٪) سهم کمتری از داده‌ها را تشکیل می‌دهد. این نتایج نشان می‌دهد که عمده پروازهای ثبت‌شده در این مجموعه داده با هدف سفرهای کاری انجام شده‌اند.
- کلاس سفر: توزیع متغیر Class نشان می‌دهد که کلاس Business با ۴۷.۸۰٪ بیشترین سهم را دارد و پس از آن Eco با ۴۴.۹۹٪ قرار گرفته است. همچنین Eco Plus تنها ۷.۲۱٪ از مشاهدات را شامل می‌شود. این توزیع بیانگر آن است که بیشتر مسافران از کلاس‌های Business و Eco استفاده کرده‌اند و سهم کلاس Eco Plus خیلی محدودتر است.
- رضایت: بررسی متغیر satisfaction که متغیر هدف است، نشان می‌دهد که گروه neutral or dissatisfied با ۵۸,۸۷۹ نفر (۵۶.۶۷٪) بیشترین فراوانی را دارد، در حالی که satisfied با ۴۵,۰۲۵ نفر (۴۳.۳۳٪) در رتبه بعدی قرار می‌گیرد. این نتایج نشان می‌دهد که بیش از نیمی از مسافران رضایت


⁴ Nominal

کامل از خدمات ارائه شده نداشته‌اند و این موضوع می‌تواند بیانگر وجود زمینه‌های نیازمندی برای بهبود کیفیت خدمات باشد.

۳.۱. تحلیل بصری

ستون‌های عددی

برای ستون‌های عددی پیوسته که قبل‌تر نیز مشخص شدند، در ابتدای کار نمودار هیستوگرام رسم می‌شود که برای نشان دادن شکل توزیع داده‌ها مفید است. همین موضوع در بخش قبلی با محاسبه skewness به صورت عددی بررسی شده بود و حالا با هیستوگرام به صورت بصری قابل مشاهده است.



«نمودار ۱»

هیستوگرام ستون سن تقریباً متقارن و شکلی نزدیک به توزیع نرمال است، بیشتر مسافران بین ۲۰ تا ۶۰ سال سن دارند و نمودار یک قله نسبتاً پهن در همین بازه نشان می‌دهد. این شکل کاملاً با آمار توصیفی همخوانی دارد؛ چون میانگین (۳۹.۳۸) و میانه (۴۰.۰۰) تقریباً برابرند و مقدار skewness نزدیک به صفر است، که یعنی داده‌ها تقریباً متقارن هستند، دقیقاً همان چیزی که در نمودار دیده می‌شود.

هیستوگرام flight distance کاملاً نامتقارن است و به سمت راست کشیدگی دارد؛ یعنی بیشتر پروازها مسافت کوتاه تا متوسط دارند اما تعداد کمی پرواز با مسافت خیلی بالا (تا ۵۰۰۰ مایل) هم وجود دارد. این مورد هم با آمار قسمت قبلی همخوانی دارد.

نمودار ستون Departure Delay in Minutes بسیار نامتقارن و به شدت به سمت راست کشیده شده است؛ اکثریت قریب به اتفاق پروازها اصلاً تاخیر ندارند یا تاخیر بسیار کمی دارند (نزدیک صفر)، اما تعداد بسیار کمی پرواز تاخیرهای خیلی زیاد (تا حدود ۱۶۰۰ دقیقه) دارند که تقریباً در نمودار دیده نمی‌شوند چون فراوانی‌شان خیلی کم است.

Departure Delay in Minute همان الگوی Departure Delay را دارد، یعنی توزیعی بسیار کشیده به راست با اکثریت مقادیر نزدیک صفر. این هم با آمار همخوانی کامل دارد؛ میانه صفر، میانگین (۱۵.۱۸) بالاتر از میانه به دلیل وجود مقادیر پرت، و skewness بسیار بالا (۶.۶۰) که نشان می‌دهد این ستون هم مثل Departure Delay دارای تعداد زیادی outlier است.

هیستوگرام‌ها به‌طور کامل با اعداد آمار توصیفی هم‌راستا هستند و یکدیگر را به‌درستی تایید می‌کنند. در ادامه تحلیل بصری این دسته از متغیرها، نمودار جعبه‌ای یا boxplot نیز برای نمایش میانه، چارک‌ها، پراکندگی داده‌ها و مهم‌تر از همه شناسایی مقادیر پرت یا outlier به کار می‌رود، که به‌خصوص برای ستون‌های تاخیر پرواز اهمیت زیادی دارد.


	Lower Bound	Upper Bound	Outlier Count	Outlier %
Age	-9.00	87.00	0	0.00
Flight Distance	-1579.50	3736.50	2291	2.20
Departure Delay in Minutes	-18.00	30.00	14529	13.98
Arrival Delay in Minutes	-19.50	32.50	13954	13.47

«جدول ۴»

در این قسمت، علاوه بر رسم boxplot برای این متغیرها در نمودار ۲، تعداد و درصد outlierها برای این متغیرها نیز در جدول ۴ نشان داده شده تا به درک بهتری برسیم.

باکس پلات Age نشان می‌دهد این ستون توزیع نسبتاً متقارن و بدون مقدار پرت دارد؛ جعبه بین چارک ۲۷ تا ۵۱ قرار گرفته، میانه (۴۰) تقریباً وسط جعبه است و هیچ داده پرتی در نمودار دیده نمی‌شود، که کاملاً با جدول IQR هم‌خوانی دارد چون Outlier Count برابر صفر است. اما باکس پلات Flight Distance وضعیت متفاوتی دارد؛ جعبه نسبتاً کوچک و در محدوده‌ی ۴۰۰ تا ۱۷۰۰ فشرده شده، ولی تعداد قابل توجهی داده پرت


در بالای نمودار دیده می‌شود که نشان‌دهنده پروازهای با مسافت خیلی طولانی هستند. این با جدول هم مطابقت دارد، چون Outlier Count این ستون ۲۲۹۱ مورد و معادل ۲.۲۰٪ از داده‌هاست؛ یعنی این پروازهای مسافت‌بلند نسبت به اکثریت داده‌ها غیرعادی محسوب می‌شوند، هرچند نسبتاً کم هستند. با وجود اینکه این متغیر داده پرت زیادی دارد، باید توجه داشت که به دلیل ماهیت خود متغیر، این داده‌های پرت در مراحل بعدی نباید حذف شوند.



«نمودار ۲»

نمودار Arrival Delay in Minutes خالی است، چرا که مقادیر NaN زیادی در این ستون وجود دارد. در این مرحله، تغییری روی آن صورت نگرفته و در مراحل بعدی به آن بیشتر پرداخته خواهد شد.

نمودار ستون Arrival Delay in Minutes به‌خاطر وجود تعداد زیادی outlier با فاصله زیاد از بقیه داده‌ها این شکل را گرفته است. طبق جدول، ۱۳.۹۸٪ از داده‌های این ستون outlier هستند، که خیلی بیشتر از بقیه ستون‌هاست. چون بعضی از این مقادیر پرت خیلی بزرگ هستند (تا ۱۶۰۰ دقیقه)، محور عمودی نمودار مجبور شده تا ۱۶۰۰ کشیده شود تا آن نقاط دور جا بگیرند؛ در نتیجه جعبه اصلی که بین صفر و ۳۰ دقیقه قرار دارد بسیار کوچک و فشرده در پایین نمودار دیده می‌شود و عملاً قابل تشخیص نیست. این حالت زمانی رخ می‌دهد که تعداد و بزرگی outlier ها خیلی زیاد باشد و مقیاس نمودار را کاملاً تحت تاثیر قرار دهد. برای درک بهتر از وضعیت، مجدداً boxplot این بخش رسم می‌شود تا وضعیت این ستون مشخص‌تر شود.



«نمودار ۳»

این نمودار به وضوح نشان می‌دهد که ستون Departure Delay in Minutes با وجود اینکه بخش اصلی داده‌ها در بازه بسیار کوچک صفر تا ۱۲ دقیقه قرار دارد، تعداد بسیار زیادی مقدار پرت دارد. تراکم این outlierها آنقدر بالاست که به جای دایره‌های جدا از هم، به صورت یک ستون توپر و فشرده دیده می‌شوند، که خودش گویای این است که تاخیرهای بالای ۳۰ دقیقه در این دیتاست نادر نیستند بلکه بخش قابل توجهی از داده‌ها را تشکیل می‌دهند. مطابق با نتایج قبلی، اکثر پروازها تاخیر کم یا صفر دارند، اما دنباله طولانی از پروازهای با تاخیر متوسط تا بالا نیز وجود دارد که نمی‌توان آن‌ها را به سادگی نادیده گرفت. این ستون نیز مثل ستون به رفتار دقیق‌تر و خاص‌تری در مواجهه با داده‌های پرت و مقادیر گم‌شده نیاز دارد و حذف این داده‌های پرت غلط است.

به منظور جمع‌بندی این بخش می‌توان گفت در مورد ستون‌های Arrival و Departure Delay in Minutes، مقادیر پرت شناسایی شده (حداقل تا سطح فعلی) در واقع خطای ثبت داده یا نویز آماری نیستند، بلکه رویدادهای واقعی و معتبر هستند؛ یعنی یک پرواز واقعا می‌تواند صد دقیقه یا حتی بیش از هزار دقیقه تاخیر داشته باشد و این اتفاق کاملاً ممکن و طبیعی است. حذف این مقادیر به معنای از دست دادن اطلاعات مهمی درباره الگوی تاخیرهای شدید پرواز خواهد بود، در حالی که همین موارد می‌توانند برای تحلیل‌های آینده بسیار ارزشمند باشند. به همین دلیل نباید این داده‌های پرت را به صورت پیش‌فرض و بدون دلیل حذف کرد. در عوض بهتر است آن‌ها را نگه داشت و در ادامه تحلیل، به جای تکیه بر میانگین و انحراف


معیار که به شدت تحت تاثیر این مقادیر پرت قرار می گیرند، از معیارهای مقاوم تر مانند میانه و IQR استفاده کرد، یا در صورت نیاز برای مدل سازی، از تبدیل هایی استفاده کرد تا اثر توزیع آن ها متعادل تر بشود.

همین منطق برای ستون Flight Distance نیز صادق است؛ پروازهای با مسافت بسیار طولانی (نزدیک به پنج هزار مایل) نیز اشتباه یا ناهنجاری در داده نیستند، بلکه دسته ای واقعی و قانونی از پروازها یعنی پروازهای بین قاره ای یا مسافت بلند را نشان می دهند. حذف این مقادیر باعث می شود دیتاست به سمت پروازهای کوتاه و متوسط تمایل پیدا کند و دیگر نماینده واقعی کل پروازها نباشد، پس این مقادیر هم باید حفظ شوند.

با این حال، نکته مهمی که باید در نظر داشت این است که این موضوع به معنای غیرقابل حذف بودن مطلق هیچ داده پرتی نیست؛ بلکه باید بین outlier آماری و خطای واقعی داده تفاوت قائل شد. برای مثال، اگر در همین ستون ها مقداری مانند تاخیر منفی پنجاه دقیقه یا مسافت پرواز صفر مشاهده شود، آن وقت این ها دیگر مقادیر پرت طبیعی نیستند بلکه خطای واقعی در داده محسوب می شوند و باید بررسی و احتمالاً حذف یا اصلاح شوند. بنابراین معیار تصمیم گیری برای حذف یا نگه داشتن داده های پرت نباید صرفاً بر پایه خروجی روش IQR باشد، بلکه باید با توجه به منطق و معنای واقعی هر ستون نیز بررسی شود.

ستون های ترتیبی

برای ستون های ترتیبی، جدول فراوانی که قبلاً ساختیم اعداد دقیق را نشان می دهد، اما درک الگوی کلی توزیع فقط از روی عدد سخت است. رسم نمودار میله ای^۵ برای هر ستون این امکان را می دهد تا درک بهتری از میزان رضایت مسافران به دست آید و روشن شود کدام جنبه های خدمات پرواز نسبت به بقیه ضعیف تر یا قوی تر ارزیابی شده اند.




«نمودار ۴»

- **Inflight wifi service**: این ستون توزیع نسبتاً متقارن با دو قله تقریباً برابر در امتیازهای ۲ و ۳ (هر کدام نزدیک به ۲۶۰۰۰). امتیاز صفر بسیار کم است و امتیاز ۵ هم نسبت به بقیه کمتر انتخاب

^۵ Bar Chart


شده (حدود ۱۱۵۰۰). این نشان می‌دهد رضایت از وای‌فای عمدتاً در سطح متوسط قرار دارد و کمتر کسی آن را عالی ارزیابی کرده.

- **Departure/Arrival time convenient:** در این متغیر، بیشتر امتیاز مربوط به ۴ است ولی امتیاز صفر هم فراوانی قابل توجهی دارد، که نشان می‌دهد بخشی از مسافران زمان‌بندی پرواز را کاملاً نامناسب دانسته‌اند.
- **Ease of Online booking:** نمودار دو قله نزدیک به هم در امتیازهای ۲ و ۳ دارد که مشابه الگوی wifi است. رضایت غالباً متوسط بوده است و کمتر مسافری امتیاز ۵ داده است.




«نمودار ۵»

- **Gate location:** توزیع این نمودار نسبتاً متقارن است و امتیاز ۳ از بقیه بیشتر دریافت شده است. هیچ داده‌ای در امتیاز صفر وجود ندارد که نشان‌دهنده سطح قابل توجهی از رضایتمندی مسافرات است. میزان رضایت عمدتاً متوسط رو به بالا (۳ و ۴) است.
- **Food and drink:** این متغیر توزیع کشیده به راست با فراوانی بالا در امتیازهای ۳، ۴ و ۵ دارد و جز در موارد محدودی، تقریباً هیچ داده‌ای در امتیاز صفر ثبت نشده است که نشان می‌دهد رضایت از غذا نسبتاً خوب، پایدار و در سطح متوسط تا بالاست.
- **Online boarding:** نمودار این ستون در دیتاست، یک نقطه اوج بسیار واضح در امتیاز ۴ دارد، با کاهش محسوس در امتیازهای پایین‌تر این یکی از واضح‌ترین الگوهای تکیله‌ای در کل مجموعه است و نشان‌دهنده رضایت بالا از فرآیند این بخش است.




«نمودار ۶»

- **Seat comfort**: این نمودار یک قله بسیار واضح در امتیاز ۴ دارد بدون هیچ داده‌ای در صفر.
- **Inflight entertainment**: این متغیر نیز دارای بیشتری فراوانی در امتیاز ۴ است و امتیاز ۵ هم فراوانی بالایی دارد، یعنی توزیع به شدت متمایل به رضایت بالاست، بدون وجود هیچ داده‌ای در امتیاز صفر.
- **On-board service**: این متغیر الگویی کاملاً مشابه Inflight entertainment دارد.



«نمودار ۷»

- **Leg room service**: بیشتر فراوانی مربوط به امتیاز ۴ است. امتیاز صفر هم مقدار کمی دارد که در سایر ستون‌های مشابه دیده نمی‌شود؛ این یعنی تعداد کمی مسافر کاملاً از فضای پا ناراضی بوده‌اند.
- **Baggage handling**: نمودار این متغیر نیز نشان می‌دهد رضایت از جابه‌جایی چمدان یکی از قوی‌ترین نقاط مثبت در کل نظرسنجی است.
- **Checkin service**: برخلاف بیشتر ستون‌ها، این یکی الگوی نسبتاً دوگانه دارد؛ امتیازهای ۱ و ۲ تقریباً برابر و کم هستند (هرکدام حدود ۱۳۰۰۰)، ولی فراوانی اصلی بین ۳ و ۴ قرار دارد (هرکدام حدود ۲۸۰۰۰-۲۹۰۰۰).




«نمودار ۸»

- **Inflight service**: این نمودار نیز دقیقا مشابه Baggage handling ، قله بسیار بلند روی امتیاز ۴ دارد، بدون امتیاز صفر است و یکی دیگر از نقاط قوت بارز خدمات پروازی است.
- **Cleanliness**: بیشترین فراوانی در امتیاز ۴ است و توزیع کشیده به راست است.

به طور کلی اکثر ستون‌ها الگوی کشیدگی به سمت راست با اوج در امتیاز ۴ دارند که نشان‌دهنده رضایت نسبتا بالای مسافران در این جنبه‌هاست. اما سه ستون Ease of Online booking ، Inflight wifi service و تا حدی Checkin service الگوی متفاوتی دارند. همچنین این الگوها کاملا با جدول قسمت قبل هم‌خوانی دارند.


ستون‌های اسمی

برای ستون‌های Categorical یعنی Gender، Customer Type، Type of Travel، Class و satisfaction، به این دلیل که این ستون‌ها هیچ ترتیب یا رتبه‌ای بین مقادیرشان ندارند (برخلاف ستون‌های ترتیبی)، به جای نمودار میله‌ای مثل قبل، برای هر ستون، تعداد و درصد هر دسته در قالب یک نمودار میله‌ای رسم شد تا هم شکل توزیع و هم عدد دقیق هم‌زمان قابل مشاهده باشد.



«نمودار ۹»

- توزیع جنسیت مسافران تقریبا متعادل است، به‌طوری‌که ۵۰.۷٪ از مسافران زن و ۴۹.۳٪ مرد هستند. این تفاوت بسیار ناچیز نشان می‌دهد که داده از نظر جنسیتی عدم تعادل قابل توجهی ندارد.
- برخلاف جنسیت، ستون Customer Type توزیع بسیار نامتوازنی دارد. ۸۱.۷٪ از مسافران در دسته Loyal Customer قرار دارند و تنها ۱۸.۳٪ جزو disloyal Customer هستند. این عدم توازن نشان می‌دهد که اکثریت قاطع مسافران این ایرلاین مشتریان وفاداری هستند.
- در ستون سوم نیز عدم توازن قابل توجهی دیده می‌شود؛ ۶۹.۰٪ از سفرها با هدف کاری (Business travel) و تنها ۳۱.۰٪ با هدف شخصی (Personal Travel) انجام شده‌اند




«نمودار ۱۰»

- توزیع کلاس پروازی هم نسبتاً نامتوازن است؛ Business و Eco با ۴۷.۸٪ و ۴۵.۰٪ تقریباً سهم برابری دارند و بیشترین تعداد مسافران را به خود اختصاص داده‌اند، در حالی که Eco Plus با تنها ۷.۲٪ سهم بسیار کوچکی از مسافران را شامل می‌شود. این الگو نشان می‌دهد اکثریت قریب به اتفاق مسافران یا کلاس بیزینس یا اکونومی معمولی را انتخاب می‌کنند، و کلاس اکونومی پلاس گزینه‌ی کم‌طرفدارتری در بین مسافران است، که این موضوع می‌تواند به دلایلی مثل تفاوت قیمت یا محبوبیت کمتر این کلاس مرتبط باشد.
- متغیر هدف نیز توزیع نسبتاً نزدیک به متوازن دارد؛ ۵۶.۷٪ از مسافران در دسته neutral or dissatisfied و ۴۳.۳٪ در دسته satisfied قرار گرفته‌اند. اگرچه این توزیع کاملاً برابر نیست، اما فاصله چندان زیادی هم ندارد (حدود ۱۳ درصد اختلاف)، که نشان می‌دهد داده از نظر کلاس هدف نسبتاً متوازن است و برخلاف ستون‌های Customer Type یا Type of Travel، مشکل عدم توازن شدید در این ستون چندان جدی نیست.

ماتریس همبستگی و ارتباط میان متغیرها

ستون‌های عددی و ترتیبی

از آنجا که متغیرهای عددی و متغیرهای ترتیبی هر دو دارای ترتیب و مقادیر قابل مقایسه هستند، در یک ماتریس همبستگی مشترک قرار داده شدند. برای این تحلیل از ضریب همبستگی Spearman استفاده شد، زیرا علاوه بر متغیرهای کاملاً عددی، برای متغیرهای ترتیبی که مقادیر آن‌ها به صورت ترتیبی (مانند امتیازهای ۱ تا ۵) ثبت شده‌اند نیز مناسب است. این ماتریس میزان و جهت رابطه بین هر دو متغیر را نشان می‌دهد؛ به طوری که مقادیر نزدیک به ۱ بیانگر رابطه مستقیم قوی، مقادیر نزدیک به -۱ بیانگر رابطه معکوس قوی و مقادیر نزدیک به صفر نشان‌دهنده نبود رابطه یکنواخت قابل توجه بین دو متغیر هستند.




«جدول ۵»

ماتریس همبستگی نشان می‌دهد که بیشتر متغیرهای مربوط به کیفیت خدمات پرواز دارای همبستگی مثبت با یکدیگر هستند، در حالی که متغیرهای عددی مانند Age، Flight Distance و شاخص‌های تاخیر با اغلب متغیرهای خدماتی همبستگی ضعیفی دارند. این موضوع بیان می‌کند که ارزیابی مسافران از کیفیت خدمات بیشتر به تجربه آن‌ها از خدمات مختلف وابسته است تا ویژگی‌های فردی یا مشخصات پرواز.

قوی‌ترین همبستگی بین Departure Delay و Arrival Delay با ضریب ۰.۷۴ مشاهده می‌شود که نشان‌دهنده ارتباط مستقیم بین تاخیر در زمان حرکت و زمان رسیدن است. همچنین، متغیرهای Inflight WiFi Service و Ease of Online Booking، Inflight Entertainment، Seat Comfort و Cleanliness و Food and Drink و Cleanliness نیز همبستگی نسبتاً بالایی دارند. این نتایج نشان می‌دهد که ابعاد مختلف کیفیت خدمات پرواز به یکدیگر وابسته بوده و به طور کلی تجربه مثبت یا منفی مسافر در یک بخش، معمولاً با ارزیابی مشابه او از سایر خدمات همراه است.

ستون‌های اسمی

از آنجا که متغیرهای اسمی فاقد ترتیب هستند، استفاده از ضرایب همبستگی مانند Pearson یا Spearman برای آن‌ها مناسب نیست. بنابراین برای بررسی میزان وابستگی بین این متغیرها از Cramér's V استفاده شد. این شاخص بر پایه آزمون کای دو^۶ محاسبه می‌شود و شدت ارتباط بین دو متغیر اسمی را در بازه ۰ تا ۱ اندازه‌گیری می‌کند. مقدار صفر نشان‌دهنده عدم وجود ارتباط و مقادیر نزدیک به یک نشان‌دهنده وابستگی قوی بین دو متغیر هستند.



«جدول ۶»

ماتریس نشان می‌دهد که شدت ارتباط بین متغیرهای اسمی در این مجموعه داده متفاوت است. قوی‌ترین ارتباط بین Type of Travel و Class با مقدار ۰.۵۵ مشاهده می‌شود که نشان می‌دهد نوع سفر (شخصی یا کاری) با کلاس پروازی انتخاب‌شده ارتباط نسبتاً قوی دارد. همچنین، متغیر Satisfaction نیز با Class و Type of Travel ارتباط نسبتاً بالایی دارد که بیانگر تاثیر این دو عامل بر میزان رضایت مسافران است.

در مقابل، متغیر Gender تقریباً با سایر متغیرهای اسمی ارتباطی ندارد و مقادیر Cramér's V آن بسیار نزدیک به صفر است. همچنین، Customer Type تنها ارتباط متوسطی با Type of Travel و ارتباط ضعیفی با Satisfaction دارد. به طور کلی، نتایج این ماتریس نشان می‌دهد که نوع سفر و کلاس پروازی مهم‌ترین


^۶ Chi-Square

متغیرهای اسمی مرتبط با رضایت مشتریان هستند، در حالی که جنسیت نقش قابل توجهی در ارتباط با سایر متغیرهای اسمی این مجموعه داده ندارد.

Violin Plot


Violin Plot یک نمودار آماری برای نمایش توزیع داده‌های عددی در گروه‌های مختلف است که ترکیبی از Box Plot و Kernel Density Estimation محسوب می‌شود. این نمودار علاوه بر اطلاعاتی مانند میانه و چارک‌ها، میزان تراکم داده‌ها که در نمودار جعبه‌ای هم قابل مشاهده بود، شکل کلی توزیع را نیز نشان می‌دهد و برای مقایسه یک متغیر عددی بین دسته‌های مختلف کاربرد دارد. دانستن این ارتباطات در یافتن الگوهایی میان رفتار مشتریان مفید است.

در این دیتاست، از Violin Plot برای بررسی ارتباط بین متغیرهای عددی و متغیرهای اسمی استفاده شد. هدف این است که مشخص شود آیا توزیع ویژگی‌های عددی در گروه‌های مختلف متفاوت است یا خیر. نمودارهای انتخاب‌شده شامل Age بر اساس Customer Type و Class برای بررسی تفاوت سنی گروه‌ها، Flight Distance بر اساس Type of Travel و Class برای بررسی تفاوت مسافت سفرها، و Delay و Arrival Delay بر اساس satisfaction برای بررسی اثر تاخیرها بر رضایت مشتری هستند. این انتخاب‌ها به دلیل ارتباط تحلیلی آن‌ها با رفتار مشتریان و هدف اصلی پروژه است.




«نمودار ۱۱»

بر اساس نمودار ۱۱، مشتریان وفادار میانه سنی بالاتری (حدود ۴۳ سال) و توزیع گسترده‌تری دارند، در حالی که مشتریان غیروفادار جوان‌تر (میانه حدود ۲۷ سال) و متمرکزتر در بازه ۲۰ تا ۴۰ سال هستند و توزیعشان حالت دوقله‌ای دارد. به‌طور کلی، سن بالاتر با وفاداری بیشتر همراه است.



«نمودار ۱۲»


طبق نمودار ۱۲، کلاس Business بالاترین میانه سنی (حدود ۴۲ سال) و توزیعی متمرکزتر در بازه بالغین دارد، در حالی که Eco Plus و Eco میانه پایین تری (حدود ۳۶-۳۷ سال) و توزیع دوقله‌ای با دامنه گسترده‌تری از سنین جوان‌تر تا مسن نشان می‌دهند. به‌طور کلی، مسافران Business عمدتاً میان‌سال هستند، در حالی که دو کلاس دیگر طیف سنی متنوع‌تری (شامل جوانان بیشتر) دارند.



«نمودار ۱۳»

با نگاه به نمودار ۱۳ مشاهده می‌کنیم که سفرهای Business میانه فاصله پرواز بسیار بالاتری (حدود ۱۰۰۰) و پراکندگی بیشتری تا نزدیک ۵۰۰۰ دارند، در حالی که سفرهای Personal عمدتاً کوتاه‌تر (میانه حدود ۶۵۰)

و متمرکز در بازه پایین هستند. به طور کلی، پروازهای کاری معمولاً مسافتی طولانی‌تر از سفرهای شخصی دارند.



«نمودار ۱۴»

در نمودار ۱۴، کلاس Business میانه فاصله پرواز بسیار بالاتری (حدود ۱۶۰۰) و پراکندگی گسترده‌تری تا نزدیک ۵۰۰۰ دارد، در حالی که Eco Plus و Eco توزیع مشابه و پایین‌تری (میانه حدود ۶۵۰) با تمرکز بر مسافت‌های کوتاه‌تر نشان می‌دهند. به طور کلی، مسافران Business عمدتاً پروازهای طولانی‌تری نسبت به دو کلاس دیگر دارند.

۲. پیش پردازش داده^۷

۱.۲. تمیزکاری اولیه

حذف برخی ستونها و بررسی یونیک بودن

در بخش‌های قبلی شناخت مختصری از متغیرها به دست آمد. بر این اساس ستون Unnamed: 0 به عنوان ستونی فاقد ارزش تحلیلی شناخته شد چرا که محتوای این ستون صرفاً iteration است؛ بنابراین در همین ابتدای کار این متغیر از دیتاست حذف شد.

در ادامه به بررسی unique بودن ستون id پرداخته شد. از آنجا که این ستون حاوی شناسه‌های منحصر به فرد برای هر مسافر است، این موضوع بررسی شد و هیچ id دوبار یا بیشتر تکرار نشده بود.

بررسی وجود رکوردهای مشابه

در این قسمت، به منظور حفظ یکپارچگی داده‌ها و جلوگیری از overfitting در مدل‌سازی، دیتاست از نظر وجود ردیف‌های تکراری مورد بررسی قرار گرفت. ابتدا با بررسی کل دیتافریم، ردیف‌های کاملاً تکراری جستجو شدند که هیچ موردی یافت نشد. در گام بعد، با حذف ستون‌های شناسایی شامل شناسه ردیف‌های بیش از حد شبیه به هم که علی‌رغم داشتن آی‌دی متفاوت، در تمامی ویژگی‌های پروازی، سطوح رضایتمندی و میزان تاخیرها کاملاً یکسان بودند، استخراج گردیدند تا اثر مخرب ردیف‌های تکراری ناشی از خطای ثبت سیستم در فاز آموزش مدل حذف شود.

بررسی محتوای ستون‌های دسته‌بندی^۸

در این مرحله، تمامی متغیرهای دسته‌بندی و ترتیبی مورد بررسی قرار گرفتند تا اطمینان حاصل شود که داده‌ها دچار خطای ثبت پنهان یا مقادیر خارج از موارد مجاز نباشند یا یک داده به اشکال مختلفی در دیتاست وارد نشده باشد که مورد اینچنینی مشاهده نشد.

^۷ در قسمتی از بخش ۱، به مشکلات موجود در دیتاست (نظیر مقادیر پرت) پی برده شد. برای حفظ یکپارچگی گزارش و فهم راحت‌تر، در بخش ۲ به این موارد بیشتر پرداخته می‌شود و تحلیل‌های لازم برای هر کدام ارائه داده می‌شود.

^۸ Categorical

۲.۲. مدیریت مقادیر گمشده

تمامی ستون‌ها بررسی شد و درصد مقادیر خالی در هر ستون، مشخص شد. تنها ستونی که مقدار خالی داشت، ستون **Arrival Delay in Minutes** بود. برای پر کردن مقادیر خالی، قبل از اعمال، سه روش مختلف بررسی می‌شود و بین آن‌ها آزمایش صورت گرفته و بهترین آن‌ها انتخاب می‌شود:

روش اول: حذف سطرهای خالی

اولین روشی که معمولاً به ذهن می‌رسد، حذف سطرهای خالی است. حذف سطرهای خالی تنها وقتی می‌تواند به مدل کمک کند، که بقیه ستون‌های سطری که حذف شده، از نظر اطلاعات برای مدل نه تنها ارزشمند نباشد، بلکه مدل را گمراه کند. در سناریوی این ستون مورد بررسی، باقی اطلاعاتی که با استفاده از حذف سطرهای خالی، از مدل حذف می‌شوند، تماماً اطلاعات مفید و کمک‌کننده هستند. به همین علت، حذف سطرهای خالی، توصیه نمی‌شود.

روش دوم: پر کردن مقادیر خالی با میانگین و میانه

استفاده از این روش به دلایل منطقی، معقول نمی‌باشد. برای مثال، اگر یک پرواز ۴ ساعت شروع داشته باشد، اما ما مقدار تاخیر رسیدن را با مقدار میانگین (برای مثال ۳۰ دقیقه) پر کنیم، نتیجه از نظر منطقی غیرمعقول خواهد بود. برای مثال ممکن نیست یک پرواز ۴ ساعت دیر پریده باشد، اما تنها ۳۰ دقیقه دیر به مقصد رسیده باشد.

روش سوم: استفاده از ستون‌های مرتبط

برای اینکه مقادیر خالی ستون با منطقی صحیح پر شود، بررسی شد که چه متغیرهایی در دیتاست، می‌توانند بهترین جایگزین برای مقادیر خالی این ستون باشند. یک ستونی که بیشترین ارتباط را با ستون **Arrival Delay in Minutes** داشت، ستون **Departure Delay in Minutes** بود. زیرا مقدار تاخیر در شروع پرواز، تاثیر مستقیم در مقدار تاخیر در رسیدن پرواز دارد. هرچقدر پرواز دیرتر شروع شود، دیرتر تمام می‌شود. این دو ستون، باهم رابطه خطی بسیار قوی دارند. به طوری که تاخیر در رسیدن، به طور کامل متأثر از تاخیر در شروع پرواز است. می‌توان از این ستون برای حدس زدن مقادیر خالی در ستون مورد نظر استفاده کرد.

برای آزمایش داده‌هایی که سالم هستند جدا می‌شوند. به صورت تصادفی پنج درصد از آن‌ها خالی می‌شوند. سپس یک بار با میانگین و یک بار با ضریب پر می‌شوند و در نهایت بررسی می‌شود که کدام روش، اعدادی

نزدیک‌تر به واقعیت تولید کرده است. برای تخمین خطا نیز از روش RMSE استفاده می‌شود. خطای کمتر به این معنا است که روش بهتر است.

با توجه به نتیجه آزمایش، روش سوم در پر کردن داده‌های ستون خالی، استفاده شد. برای پر کردن مقادیر خالی، از ضریبی تحت عنوان نسبت میانگین تاخیر در رسیدن به میانگین تاخیر در شروع پرواز استفاده شد. این نسبت در متغیر *Departure Delay in Minutes* متناظر ضرب شد و مقادیر آن در سلول‌های خالی متغیر *Arrival Delay in Minutes* جایگزین شد. این روش نه تنها از نظر منطقی، بلکه از نظر خطا، بهترین روش در میان بقیه است.

۳.۲. مدیریت داده‌های پرت

مقادیر پرت در بررسی، مقادیری هستند که از نظر عددی به شدت از نمونه دور هستند و با مقادیر اشتباه و غیرمنطقی تفاوت دارند. ستون‌هایی که می‌توانند مقادیر پرت داشته باشند، عموماً متغیرهای عددی هستند. نمره‌های رضایت مشتریان از خدمات پرواز بازه ۱ تا ۵ را در بر می‌گیرد و نمی‌تواند مقادیر پرت داشته باشد. ستون‌هایی که کاندید داشتن مقادیر پرت هستند شامل *Age*، *Flight Distance*، *Departure Delay in Minutes*، *Arrival Delay in Minutes* هستند.

ستون Age

سن زیر ۱۲ سال داده پرت محسوب می‌شود، زیرا افراد زیر ۱۲ سال، درک کافی از معیارهای ارزیابی ندارند، و داده‌هایی که پر کرده‌اند ممکن است کاملاً تصادفی باشد. و نتیجه مدل را تغییر دهد.

از طرفی سن بالای ۸۵ سال نیز داده پرت محسوب می‌شود. پر کردن یک پر کردن دقیق یک پرسشنامه طولانی برای افراد بسیار مسن ممکن است خسته‌کننده باشد. در بسیاری از مواقع این فرم‌ها یا به صورت ناقص پر می‌شوند یا توسط همراهان مسافر تکمیل می‌شوند که نشان‌دهنده نظر واقعی خود شخص نیست. در صنعت هوایی، مسافران بالای ۸۵ سال درصد بسیار کوچکی را تشکیل می‌دهند. اگر در دیتاست با سنین مثل ۹۵ یا ۱۰۰ مواجه شویم، احتمال اینکه این اعداد ناشی از خطای تایپی در ثبت اطلاعات باشند بسیار بیشتر از این است که واقعاً مربوط به یک مسافر در آن سن باشند. در نتیجه این اقدام، ۳۲۵۵ رکورد از دیتاست حذف شد.

ستون Flight Distance

این ستون توسط فرودگاه پر می‌شود، و نه پرکنندگان پرسش‌نامه. به همین علت احتمال خطا و داده پرت در این ستون، بسیار پایین خواهد بود. برای اطمینان از این مساله، کمترین و بیشترین مقدار پرواز بررسی شد. بیشترین مسافت ۴۹۸۳ مایل و کمترین مسافت ۳۱ مایل است.

با توجه به مقادیر، بازه مسافت پرواز مشخص شده و هیچ کدام از آن‌ها داده پرت بودن نخواهند بود.

ستون‌های Departure Delay in Minutes و Arrival Delay in Minutes

این دو ستون مربوط به تاخیرهای شروع پرواز و تاخیرهای رسیدن به مقصد هستند. برای بررسی مقادیر پرت در این ستون‌ها، مقدار ماکسیمم و مینیمم ستون‌ها شناسایی شد. و بازه ۰.۰۰۱ بالایی بیشترین تاخیر نیز شناسایی شد.

برای درک بهتر، بالاترین مقادیر تاخیر در هر دو ستون sort و print شد. مشاهده می‌شود که ۱۵ رکوردی که بیشترین مقدار تاخیر را دارند، در بازه حدود ۶۰۰ دقیقه الی ۱۶۰۰ دقیقه هستند. پس تنها ۱۵ رکورد وجود دارد که بیشتر از ۶۰۰ دقیقه تاخیر برای آن‌ها ثبت شده.

با توجه به نتایج، احتمالاً مسافری که ۶ ساعت تاخیر داشته، از نظر متغیرهای پرسشنامه، به اندازه مسافری که ۲۶ ساعت تاخیر داشته است، ناراضی است، پس برای کمتر شدن نویز داده‌ها، ۰.۱ درصد بالایی این ستون‌ها با روش Capping مقدارشان به مقدار ماکسیمم ۹۹.۹ درصد بقیه داده‌ها تغییر داده شد. با توجه به نتایج، برای مثال، مقدار ۱۵۸۴ دقیقه، به مقدار ۳۸۳ دقیقه تغییر پیدا کرده است. این کار به علت کمتر شدن نویز داده‌ها انجام شد. و ۱۱۱ ردیف، از این کار تاثیر گرفتند.

Departure Delay in Minutes	Arrival Delay in Minutes
81142	1592
6539	1305
59432	1017
69992	978
77697	933
59409	930
59648	921
26898	859
50257	853
35959	750
64685	748
49204	729
9703	726
27232	692
7914	652

«جدول ۷»

رسیدگی به مقادیر غیرمنطقی و اشتباه

برای بررسی مقادیر غیرمنطقی و اشتباه، برای هرستون با توجه به ماهیت آن استراتژی متفاوتی را به کار می‌گیریم.

ستون‌های ترتیبی

ستون‌هایی هستند که نمره مسافری به خدمات و تجربه پرواز آنها است، که از ۱ تا ۵ نمره دهی می‌شود. بدیهی است که هر نمره‌ای خارج از این بازه، داده اشتباه تلقی می‌شود و آن داده حذف می‌شود. همانطور که در قسمت‌های قبل مشاهده شد، هیچ ردیفی در این ستون‌های مد نظر، مقدار اشتباه نداشت.

ستون‌های عددی

درمورد این ستون‌ها، مقادیر منفی غیرمجاز است. پس وجود مقادیر منفی بررسی می‌شود. با توجه به نتایج، هیچ موردی مبنی بر داده منفی یافت نشد.

۴.۲. نرمال‌سازی و استانداردسازی

استانداردسازی

داده‌ها را طوری تغییر می‌دهد که میانگین آن‌ها برابر با صفر و انحراف معیارشان برابر با یک شود. نشان می‌دهد که هر داده چقدر از میانگین کل آن ستون فاصله دارد. در این روش مقادیر می‌توانند منفی یا مثبت باشند. این روش معمولاً در زمانی که داده‌ها توزیع نرمال دارند یا زمانی که الگوریتم ما به داده‌های متمرکز حول صفر نیاز دارد، کاربردی است.

نرمال‌سازی

تمام داده‌های یک ستون را فشرده می‌کند تا دقیقاً در یک بازه مشخص (معمولاً بین صفر تا یک) قرار بگیرند. این روش معمولاً زمانی کاربرد دارد که داده‌ها توزیع نرمال ندارند.

استانداردسازی و نرمال‌سازی، در برخی از الگوریتم‌ها به‌خاطر ماهیتشان، مانند رگرسیون لجستیک، KNN و SVM ضروری هستند، چون این الگوریتم‌ها بر پایه‌ی فاصله یا گرادیان عمل می‌کنند و ویژگی‌های با مقیاس بزرگ‌تر (مانند Flight Distance با دامنه‌ی چند هزار واحدی) می‌توانند به‌طور غیرمنصفانه بر ویژگی‌های با مقیاس کوچک‌تر (مانند امتیازهای رضایت در بازه‌ی ۱ تا ۵) غالب شوند. در مقابل، در برخی الگوریتم‌ها مانند Random Forest، XGBoost و درخت تصمیم که بر اساس threshold تقسیم‌بندی انجام می‌دهند، عمل می‌کنند، مقیاس ویژگی‌ها هیچ تاثیری بر عملکرد مدل ندارد.

با توجه به این که ستون‌های موجود در دیتاست شامل هم متغیرهای امتیازی با بازه‌ی محدود (۱ تا ۵) و هم متغیرهای مسافتی و زمانی با دامنه‌ی مقادیر بسیار بزرگ‌تر هستند، و با توجه به این که در بخش پیش‌پردازش، مقادیر پرت شدید با روش Capping کنترل شدند، استانداردسازی به‌عنوان روش مناسب برای آماده‌سازی داده‌های عددی و ترتیبی جهت استفاده در الگوریتم‌های حساس به مقیاس انتخاب شد.

با این حال، از آنجا که مراحل بعدی پروژه شامل بررسی تعادل کلاس‌ها، انتخاب ویژگی^۹ و همچنین پیاده‌سازی چند مدل مختلف (از جمله رگرسیون لجستیک و Random Forest) است، و این مراحل نیاز یکسانی به داده‌ی استاندارد شده ندارند، تصمیم گرفته شد به‌جای اعمال استانداردسازی مستقیم روی دیتاست اصلی، دو نسخه مستقل و کامل از دیتاست ساخته و ذخیره شود.

نسخه نخست با نام `dfs_unscaled`، عیناً برابر با دیتاست پس از اتمام مراحل پیش‌پردازش است و هیچ تغییری در مقیاس ستون‌های عددی آن اعمال نشده است؛ این نسخه برای مراحل که نیازمند مقادیر اصلی و قابل‌تفسیر هستند به‌کار می‌رود، از جمله بررسی تعادل کلاس هدف، روش‌های انتخاب ویژگی مبتنی بر آزمون Chi-Square که به مقادیر غیرمنفی نیاز دارد و مدل‌سازی با الگوریتم‌های مبتنی بر درخت مانند Random Forest که به مقیاس داده حساس نیستند.

نسخه دوم با نام `dfs_scaled`، از روی همان دیتاست پیش‌پردازش شده ساخته شد، با این تفاوت که ستون‌های عددی پیوسته و ترتیبی آن با استفاده از `StandardScaler` استاندارد شدند (میانگین صفر و انحراف معیار یک)؛ این نسخه مخصوص الگوریتم‌هایی مانند رگرسیون لجستیک است که عملکردشان به مقیاس ویژگی‌ها وابسته است.

هر دو نسخه در قالب فایل‌های CSV جداگانه ذخیره شدند تا در مراحل بعدی پروژه، بسته به نیاز هر الگوریتم، نسخه‌ی مناسب مستقیماً فراخوانی و استفاده شود، بدون نیاز به تکرار فرآیند پیش‌پردازش یا استانداردسازی. لازم به ذکر است که تنها ستون‌های عددی و ترتیبی (مانند سن، مسافت پرواز، مقادیر تاخیر و امتیازهای رضایت) مشمول استانداردسازی شدند و ستون‌های دسته‌ای (nominal) بدون تغییر باقی ماندند، چراکه این ستون‌ها در مراحل بعدی نیازمند رمزگذاری جداگانه (مانند One-Hot Encoding) هستند و منطق استانداردسازی برای آن‌ها معنادار نیست.

۵.۲. بررسی تعادل کلاس‌ها

پس از اتمام مراحل قبلی، لازم است توزیع متغیر هدف (satisfaction) در دیتاست بررسی شود، زیرا عدم تعادل شدید بین کلاس‌ها می‌تواند در مراحل بعدی، به‌ویژه مدل‌سازی، عملکرد الگوریتم‌های یادگیری ماشین

^۹ Feature Selection

را به سمت کلاس اکثریت متمایل کند و دقت پیش‌بینی برای کلاس اقلیت را کاهش دهد. به همین منظور، در این بخش ابتدا تعداد و درصد دقیق هر یک از دو کلاس متغیر هدف محاسبه می‌شود. سپس با استفاده از شاخص نسبت عدم تعادل^{۱۰}، که از تقسیم فراوانی کلاس اکثریت بر فراوانی کلاس اقلیت به دست می‌آید، شدت این عدم تعادل به صورت کمی اندازه‌گیری می‌شود. در ادامه، به منظور درک بهتر و شهودی‌تر توزیع، نمودار میله‌ای مربوط به فراوانی هر کلاس نیز رسم می‌شود. لازم به ذکر است که این بررسی صرفاً بر روی داده‌های مجموعه train انجام می‌شود، چراکه هرگونه تصمیم‌گیری درباره متعادل‌سازی داده (در صورت نیاز) باید مبتنی بر داده‌ی آموزشی باشد و مجموعه تست باید بدون دست‌کاری و با توزیع طبیعی خود باقی بماند تا ارزیابی نهایی مدل واقع‌بینانه انجام شود. نتیجه این بررسی، مبنای تصمیم‌گیری درباره‌ی نیاز یا عدم نیاز به تکنیک‌های متعادل‌سازی در مراحل بعدی خواهد بود.

با توجه به جدول ۸، بررسی توزیع متغیر هدف satisfaction در مجموعه داده train نشان می‌دهد که کلاس neutral or dissatisfied با ۵۶,۰۴۳ رکورد (۵۵.۶۸٪) کلاس اکثریت، و کلاس satisfied با ۴۴,۶۰۶ رکورد (۴۴.۳۲٪) کلاس اقلیت است. فاصله بین این دو کلاس تنها حدود ۱۱.۴ درصد است که فاصله چندان بزرگی محسوب نمی‌شود.


	Count	Percentage
Satisfaction Class		
neutral or dissatisfied	56,043	55.68%
satisfied	44,606	44.32%

«جدول ۸»

شاخص نسبت عدم تعادل برابر با ۱.۲۶ به دست آمد؛ یعنی کلاس اکثریت تنها ۱.۲۶ برابر کلاس اقلیت فراوانی دارد. با توجه به قاعده رایج که نسبت‌های زیر ۱.۵ را تقریباً متوازن در نظر می‌گیرد، این عدد به وضوح در محدوده تعادل نسبی قرار می‌گیرد و فاصله زیادی با اختلاف‌های نگران‌کننده نسبت‌های بالای ۳ یا ۴ که معمولاً نشان‌دهنده عدم تعادل شدید هستند دارد.

نمودار میله‌ای نیز همین یافته را به صورت بصری تایید می‌کند. دو ستون از نظر ارتفاع تفاوت محسوسی دارند، اما این تفاوت به اندازه‌ای نیست که یکی از کلاس‌ها را به طور قطعی به عنوان minority قرار گیرد. هر دو کلاس سهم قابل توجهی (بیش از ۴۴٪) از داده را به خود اختصاص داده‌اند.

¹⁰ Imbalance Ratio



«نمودار ۱۵»

با توجه به نسبت عدم تعادل ۱.۲۶ که در محدوده‌ی تعادل نسبی قرار دارد، نیازی به اعمال تکنیک‌های شدید متعادل‌سازی مانند SMOTE، Oversampling یا Undersampling دیده نمی‌شود. اعمال چنین تکنیک‌هایی برای عدم تعادلی به این خفیفی، معمولاً بهبود محسوسی در عملکرد مدل ایجاد نمی‌کند و حتی می‌تواند با تولید نمونه‌های مصنوعی غیرضروری (در مورد SMOTE) یا از دست دادن داده واقعی (در مورد Undersampling) ریسک غیرضروری به فرآیند مدل‌سازی اضافه کند.

با این حال، به منظور اطمینان از این که مدل در پیش‌بینی هر دو کلاس عملکرد متوازنی داشته باشد، در مرحله مدل‌سازی از پارامتر `'class_weight='balanced'` (که در الگوریتم‌هایی مانند Logistic Regression و Random Forest به صورت درون‌ساخت پشتیبانی می‌شود) استفاده خواهد شد. این رویکرد بدون نیاز به دست‌کاری داده‌ها، به مدل اجازه می‌دهد در فرآیند یادگیری، وزن بیشتری به خطاهای مربوط به کلاس اقلیت بدهد و از تمایل مدل به سمت کلاس اکثریت جلوگیری کند.

۶.۲. انتخاب و مهندسی ویژگی‌ها

پس از اطمینان از تعادل نسبی متغیر هدف، در این بخش به بررسی و انتخاب ویژگی‌های نهایی برای مرحله مدل‌سازی پرداخته می‌شود. هدف از این مرحله، شناسایی ویژگی‌هایی است که ارتباط معنادار و قابل توجهی با متغیر هدف دارند و در عین حال، از وجود اطلاعات تکراری بین ویژگی‌ها که می‌تواند باعث پیچیدگی غیرضروری مدل یا مشکل هم‌خطی^{۱۱} شود، جلوگیری شود.

^{۱۱} Multicollinearity

برای این امر، ابتدا لازم است ستون‌های فاقد ارزش تحلیلی (مانند شناسه‌ی ردیف) حذف شوند که در قسمت‌های قبلی انجام شده است. سپس، با توجه به ماهیت متفاوت ویژگی‌ها ارتباط هر یک با متغیر هدف با استفاده از آزمون‌های آماری مناسب سنجیده می‌شود.

در ادامه، با استفاده از ماتریس‌های همبستگی که پیش‌تر در بخش تحلیل بصری ساخته شدند، ویژگی‌های دارای همبستگی بالا با یکدیگر شناسایی و بررسی می‌شوند تا در صورت وجود اطلاعات تکراری، تصمیم مناسب درباره حذف یا نگه‌داشتن هر یک اتخاذ شود. علاوه بر تحلیل‌های آماری، اهمیت ویژگی‌ها از منظر مدل یادگیری ماشین نیز با دو روش اهمیت مبتنی بر کاهش ناخالصی و اهمیت مبتنی بر جایگشت بررسی می‌شود تا دیدگاهی مکمل بر تحلیل‌های آماری فراهم گردد.

در نهایت، برای اطمینان از این‌که حذف یا نگه‌داشتن ویژگی‌ها بر پایه شواهد عملی نیز استوار است، عملکرد مدل با استفاده از تمامی ویژگی‌ها در مقابل مجموعه‌ی ویژگی‌های منتخب، با روش اعتبارسنجی Cross-Validation بر روی داده train مقایسه می‌شود. تمامی این مراحل صرفاً بر روی دیتاست train انجام می‌شود و test بدون هیچ‌گونه دخالتی، صرفاً برای ارزیابی نهایی مدل در انتهای پروژه کنار گذاشته می‌شود.

مرحله ۰: جداسازی داده train و test

برای انتخاب ویژگی‌ها، باید توجه داشت که این پروسه باید روی داده‌های train انجام گیرد. در این پروژه، این دو دیتاست از ابتدا از یکدیگر جدا بودند و نیازی نیست که جداسازی انجام شود ولی در صورتی که تنها یک فایل داده موجود بود، باید جداسازی انجام می‌شد و بعد ادامه مراحل انجام می‌شد.

مرحله ۱: حذف ویژگی‌های بدون ارزش و با واریانس صفر

قبل از هر آزمون آماری، ستون‌هایی مثل id که صرفاً شناسه هستند و ارزش تحلیلی ندارند، حذف می‌شوند. همچنین اگر ستونی واریانس نزدیک صفر داشته باشد، یعنی تقریباً تمامی رکوردهای آن یکی باشد، حذف می‌شوند؛ چراکه ستونی که تقریباً برای همه رکوردها مقدار یکسانی دارد، هیچ اطلاعات مفیدی برای تفکیک کلاس‌های متغیر هدف در اختیار مدل قرار نمی‌دهد و وجودش صرفاً پیچیدگی غیرضروری به دیتاست اضافه می‌کند. برای این بررسی، ستون‌های عددی پیوسته و ترتیبی از نظر مقدار واریانس، و ستون‌های اسمی از نظر نسبت پرتکرارترین دسته نسبت به کل داده مورد بررسی قرار گرفتند.

نتایج نشان داد که در ستون‌های عددی و ترتیبی، مقادیر واریانس در بازه‌ای معقول و متناسب با ماهیت هر ستون قرار دارند؛ ستون‌های ترتیبی رضایت مسافران (با بازه‌ی امتیازی ۰ تا ۵) واریانسی بین ۱.۳۹ تا ۲.۰۶ دارند که نشان‌دهنده‌ی استفاده واقعی مسافران از کل بازه امتیازدهی است، و ستون‌های عددی پیوسته مانند سن، مسافت پرواز و مقادیر تاخیر، با توجه به دامنه‌ی بزرگ‌تر مقادیرشان، به‌طور طبیعی واریانس بسیار

بالا تری دارند. این تفاوت مقیاس، پیش تر نیز دلیل اصلی نیاز به استاندارد سازی این ستون ها بود، اما از منظر Feature Selection، هیچ ستونی به اندازه ای بی تحرک نبود که کاندید حذف باشد.

در مورد ستون های اسمی نیز، پرتکرار ترین دسته در هر ستون سهمی بین ۴۸.۹ درصد (Class) تا ۸۱.۵ درصد (Customer Type) از کل داده را به خود اختصاص می دهد. اگرچه ستون هایی مانند Customer Type و Type of Travel نسبت به Gender و Class توزیع نامتوازن تری دارند، هیچ کدام به آستانه رایج برای حذف که معمولاً بالای ۹۵ تا ۹۹ درصد تمرکز در یک دسته نمی رسند و همچنان دارای تنوع کافی برای مشارکت در تحلیل های بعدی هستند.

بر این اساس، در این مرحله هیچ ویژگی ای به دلیل فقدان واریانس یا عدم تنوع کافی از دیتاست حذف نشد و تمامی ستون های باقی مانده به مرحله ی بعدی، یعنی سنجش ارتباط هر ویژگی با متغیر هدف، منتقل می شوند. لازم به ذکر است که در این بررسی، واریانس متغیرها با یکدیگر مقایسه نشدند بلکه هر کدام جداگانه سنجیده شدند.

مرحله ۲: سنجش ارتباط هر ویژگی با متغیر هدف

این مرحله چند گام دارد که به ترتیب آورده و تحلیل می شوند:

گام ۱

اول متغیر هدف به ۰ و ۱ تبدیل می شود زیرا بعضی آزمون ها و محاسبات، مثل rank-biserial، به فرم عددی نیاز دارند و بعد دیتاست بر اساس مقدار satisfaction به دو گروه جدا تقسیم می شوند.

گام ۲

برای هر یک از ستون های موجود در int_cols که شامل هر دو دسته متغیرهای عددی پیوسته، نظیر سن، و متغیرهای ترتیبی، نظیر امتیازهای رضایت، می شود، توزیع مقادیر آن ها میان دو گروه رضایت مند و ناراضی مورد مقایسه قرار می گیرد. مقدار p-value نشان دهنده معناداری آماری این تفاوت است؛ با این حال، با توجه به حجم بالای نمونه، تقریباً تمامی مقادیر p-value به طور معناداری کوچک به دست می آیند. از این رو، شاخص مهم تر در این تحلیل، ضریب همبستگی رتبه ای دوسویه است که میزان قدرت تفاوت میان دو گروه را نشان می دهد، نه صرفاً معناداری آماری آن را.

Feature	U-statistic	p-value	Effect Size (rank-biserial)
Online boarding	465,315,553	0.0000e+00	0.6277
Inflight entertainment	677,345,954	0.0000e+00	0.4581
Seat comfort	734,872,361	0.0000e+00	0.4121
On-board service	778,791,933	0.0000e+00	0.3769
Leg room service	789,057,970	0.0000e+00	0.3687
Cleanliness	815,513,404	0.0000e+00	0.3476
Inflight wifi service	825,599,865	0.0000e+00	0.3395
Baggage handling	864,434,101	0.0000e+00	0.3084
Inflight service	870,619,921	0.0000e+00	0.3035
Flight Distance	873,750,086	0.0000e+00	0.3010
Checkin service	915,763,648	0.0000e+00	0.2673
Food and drink	954,152,006	0.0000e+00	0.2366
Ease of Online booking	991,252,614	0.0000e+00	0.2070
Age	1,074,295,424	0.0000e+00	0.1405
Arrival Delay in Minutes	1,380,004,276	3.7532e-215	-0.1041
Departure Delay in Minutes	1,337,301,694	1.2430e-98	-0.0699
Departure/Arrival time convenient	1,316,179,202	1.8245e-49	-0.0530
Gate location	1,250,716,966	8.5972e-01	-0.0006

«جدول ۹»

نتایج آزمون Mann-Whitney U برای بررسی ارتباط ستون‌های عددی و ترتیبی با متغیر هدف نشان می‌دهد که اکثر ویژگی‌های مرتبط با خدمات پرواز، ارتباط قوی و معناداری با رضایت نهایی مسافران دارند. قوی‌ترین ارتباط مربوط به Online boarding با اندازه‌اثر ۰.۶۲۸ است که به‌طور محسوسی از سایر متغیرها فاصله دارد و نشان می‌دهد فرآیند دریافت آنلاین کارت پرواز نقش تعیین‌کننده‌ای در رضایت کلی مسافران ایفا می‌کند. پس از آن، متغیرهایی مانند Inflight entertainment، On-board service، Leg room service، Cleanliness، Inflight wifi service و Baggage handling قرار دارند که همگی اثر قابل‌توجهی داشته و با یافته‌های پیشین در بخش تحلیل بصری و ماتریس همبستگی Spearman هم‌راستا هستند.

در سطوح بعدی، متغیرهایی مانند Inflight service، Flight Distance، Checkin service، Food and drink نیز ارتباط معناداری با رضایت مسافران نشان می‌دهند. حضور Flight Distance در این گروه قابل‌توجه است، چراکه برخلاف سایر ویژگی‌ها که مستقیماً به خدمات پرواز مربوط‌اند، این متغیر به مسافت سفر اشاره دارد؛ با توجه به تحلیل پیشین Violin Plot که نشان داد پروازهای مسافت‌بلندتر عمدتاً به کلاس Business تعلق دارند، این ارتباط می‌تواند ناشی از تفاوت سطح خدمات میان کلاس‌های پروازی باشد. متغیرهای Ease of Online booking، Age نیز در سطح پایین‌تری قرار دارند، اما همچنان دارای ارتباط قابل‌ملاحظه با متغیر هدف هستند.

در مقابل، چهار متغیر Departure/Arrival، Departure Delay in Minutes، Arrival Delay in Minutes، Gate location، time convenient اندازه اثر بسیار پائینی نشان دادند. علامت منفی در دو متغیر تاخیر، بیانگر رابطه معکوس منطقی است؛ یعنی تاخیر بیشتر همراه با رضایت کمتر است، اما بزرگی این اثر آنقدر ناچیز است که نشان می‌دهد این دو متغیر به تنهایی قدرت تفکیک‌کنندگی محدودی برای پیش‌بینی رضایت مسافر دارند؛ این موضوع نشان می‌دهد ارزیابی نهایی مسافران از سفر، بیشتر متأثر از کیفیت خدمات دریافتی است تا صرفاً زمان‌بندی پرواز.

نکته قابل‌توجه‌تر مربوط به متغیر Gate location است که علاوه بر اندازه اثر تقریباً صفر، دارای p-value برابر با ۰.۸۶ نیز است؛ این تنها متغیری است که در این آزمون از نظر آماری نیز معنادار نبوده و بنابراین به‌عنوان کاندید اصلی حذف در مراحل بعدی تحلیل شناسایی می‌شود. با این حال، تصمیم قطعی درباره حذف این متغیر و همچنین بررسی بیشتر متغیرهای با اثر ضعیف، منوط به بررسی نتایج مراحل بعدی، از جمله اهمیت مبتنی بر مدل و مقایسه‌ی عملکرد با اعتبارسنجی متقابل، خواهد بود.

برای ستون‌های categorical، یک Contingency Table میان آن ستون و متغیر satisfaction ساخته می‌شود و آزمون Chi-Square بر روی آن اجرا می‌شود. علاوه بر مقدار p-value، ضریب Cramér's V نیز محاسبه می‌گردد که شدت رابطه میان دو متغیر را در بازه صفر (عدم وجود رابطه) تا یک (رابطه کامل) نشان می‌دهد. همچنین اطمینان حاصل می‌شود که کمترین فراوانی مورد انتظار در جدول توافقی حداقل برابر با ۵ باشد، چرا که در غیر این صورت، نتیجه‌ی آزمون Chi-Square از اعتبار کافی برخوردار نخواهد بود.

Feature	Chi2	p-value	Cramér's V	Min Expected Freq
Class	25,407.29	0.0000e+00	0.5024	3,149.71
Type of Travel	19,904.35	0.0000e+00	0.4447	13,162.11
Customer Type	3,890.25	0.0000e+00	0.1966	8,251.19
Gender	15.81	6.9959e-05	0.0125	21,960.20

«جدول ۱۰»

با توجه به جدول ۱۰، نتایج آزمون Chi-Square و شاخص Cramér's V برای بررسی ارتباط ستون‌های اسمی با متغیر هدف نشان می‌دهد که تمامی چهار متغیر از نظر آماری معنادار هستند. p-value برای هر چهار ستون بسیار کوچک و کمتر از سطح معناداری است، اما شدت این ارتباط بین متغیرها تفاوت قابل توجهی دارد. متغیر Class با Cramér's V برابر با ۰.۵۰۲۴ قوی‌ترین ارتباط را با رضایت مسافران نشان می‌دهد که در دسته‌بندی رایج این شاخص، در مرز بالای ارتباط متوسط تا قوی قرار می‌گیرد؛ این یافته نشان می‌دهد کلاس پروازی یکی از مهم‌ترین عوامل تعیین‌کننده در رضایت نهایی مسافر است. پس از آن، Type of Travel با

مقدار ۰.۴۴۴۷. نیز ارتباط نسبتاً قوی‌ای دارد و نشان می‌دهد هدف سفر نقش قابل توجهی در ارزیابی مسافر از تجربه پرواز ایفا می‌کند. این دو یافته کاملاً با نتایج ماتریس Cramér's V در بخش تحلیل‌های اولیه گزارش هم‌راستا هستند، جایی که همین دو متغیر به‌عنوان مهم‌ترین متغیرهای اسمی مرتبط با رضایت شناسایی شده بودند. در مقابل، Customer Type با مقدار ۰.۱۹۶۶. ارتباط متوسطی نشان می‌دهد که همچنان قابل توجه است، اما به‌وضوح ضعیف‌تر از دو متغیر پیشین است.

برای متغیر جنسیت، اگرچه رابطه Gender از نظر آماری معنادار است، مقدار Cramér's V برابر با ۰.۰۱۲۵. نشان می‌دهد شدت این رابطه از نظر عملی تقریباً ناچیز است. معناداری آماری آن احتمالاً ناشی از حجم بالای نمونه است.

از طرفی ستون Min Expected Freq نیز نشان می‌دهد که کمترین فراوانی مورد انتظار در تمامی جداول توافقی به‌مراتب بیشتر از آستانه رایج (۵) است؛ کمترین مقدار آن مربوط به Class با ۳,۱۴۹.۷۱ است که با فاصله زیادی از این آستانه بالاتر قرار دارد. این موضوع تضمین می‌کند که پیش‌فرض‌های آماری آزمون- χ^2 Square در مورد تمامی چهار متغیر برقرار بوده و نتایج به‌دست‌آمده قابل اعتماد هستند.

با توجه به این نتایج، Class و Type of Travel به‌عنوان دو متغیر اسمی با ارتباط قوی، Customer Type به‌عنوان متغیری با ارتباط متوسط برای نگه‌داری در مراحل بعدی در نظر گرفته می‌شوند، در حالی که Gender با توجه به اندازه‌اثر تقریباً صفر، به‌همراه Gate location که در آزمون Mann-Whitney نیز مشابه این نتیجه را نشان داد، به‌عنوان کاندیدهای اصلی حذف در بررسی‌های تکمیلی مرحله بعدی شناسایی می‌شوند.

مرحله ۳: بررسی همبستگی و redundancy بین متغیرها

برای این گام از دو ماتریسی که پیش‌تر ارائه شد (ماتریس همبستگی Spearman برای متغیرهای عددی و ترتیبی، و ماتریس Cramér's V برای متغیرهای اسمی) استفاده می‌شود.

Feature 1	Feature 2	Spearman Correlation
Departure Delay in Minutes	Arrival Delay in Minutes	0.7416
Inflight wifi service	Ease of Online booking	0.7038

«جدول ۱۱»

بررسی جفت‌ویژگی‌های دارای همبستگی بالا، با Spearman بیش‌تر یا مساوی ۰.۷ در میان متغیرهای عددی و ترتیبی، دو جفت را نشان داد. جفت نخست، Departure Delay in Minutes و Arrival Delay in Minutes، با همبستگی ۰.۷۴۱۶ بود که چندان دور از انتظار نیست، چون منطقاً هرچه پرواز دیرتر شروع شود، احتمال دیرتر رسیدن هم بیشتر است. با این حال، باید به این نکته توجه داشت که بخشی از این مقادیر

گمشده Arrival Delay پیش‌تر با استفاده از نسبتی از Departure Delay پر شده بودند؛ بنابراین بخشی از این همبستگی می‌تواند ناشی از همان فرآیند پرکردن مقادیر گمشده باشد و نه صرفاً یک رابطه طبیعی موجود در داده. از طرفی، در آزمون Mann-Whitney هر دو متغیر اندازه‌اثر نسبتاً ضعیفی با satisfaction داشتند. به همین دلیل به جای تصمیم‌گیری قطعی در همین مرحله، هر دو نگه داشته می‌شوند تا در مرحله مقایسه عملکرد، مشخص شود حذف کدامیک (در صورت نیاز) تاثیر بهتری بر مدل دارد.

جفت دوم، Inflight wifi service و Ease of Online booking، با همبستگی ۰.۷۰۳۸ به‌دست آمد. این جفت با جفت قبلی فرق دارد، چون از نظر مفهومی این دو متغیر به دو بخش کاملاً جدا از تجربه مسافر مربوط می‌شوند: یکی کیفیت اینترنت داخل هواپیما و دیگری سادگی فرآیند رزرو آنلاین بلیط، پیش از پرواز. به نظر می‌رسد این همبستگی بیشتر از یک الگوی رفتاری کلی‌تر می‌آید؛ مثلاً مسافری که به‌طور کلی از خدمات دیجیتال و آنلاین ایرلاین راضی است، احتمالاً به هر دو مورد امتیاز نزدیک به هم می‌دهد، نه اینکه این دو مستقیماً روی هم اثر بگذارند. با توجه به اینکه Inflight wifi service ارتباط به مراتب قوی‌تری با satisfaction دارد (۰.۳۳۹ در برابر ۰.۲۰۷) و هر دو متغیر همچنان معنای مستقل و قابل‌فهم خودشان را دارند، تصمیم گرفته شد هر دو در دیتاست باقی بمانند و این جفت به‌عنوان کاندید حذف در نظر گرفته نشود.

Feature 1	Feature 2	Cramér's V
Type of Travel	Class	0.5485

«جدول ۱۲»

از بین متغیرهای اسمی نیز تنها یک جفت با همبستگی بالا شناسایی شد Type of Travel و Class، با Cramér's V برابر ۰.۵۴۸۵. این ارتباط منطقی به نظر می‌رسد، به این دلیل که معمولاً سفرهای کاری بیشتر با کلاس Business همراه‌اند و سفرهای شخصی بیشتر به کلاس‌های اقتصادی‌تر گرایش دارند. با این حال، هر دو متغیر در آزمون Chi-Square ارتباط قوی و مستقلی هم با satisfaction نشان دادند. به همین دلیل هر دو نگه داشته می‌شوند و تصمیم نهایی درباره‌ی حذف احتمالی یکی از آن‌ها، مانند جفت‌های قبلی، به مرحله‌ی مقایسه‌ی عملکرد مدل موکول می‌شود.

مرحله ۴: بررسی اهمیت مبتنی بر مدل^{۱۲}

در کنار آزمون‌های آماری انجام‌شده در مراحل قبل که رابطه هر ویژگی را به‌صورت مجزا و عمدتاً خطی با متغیر هدف می‌سنجیدند، در این مرحله از یک مدل یادگیری ماشین برای ارزیابی اهمیت ویژگی‌ها استفاده

¹² Model-based Importance

می‌شود. دلیل این کار آن است که برخی الگوها و روابط، به‌ویژه اثرات غیرخطی یا ترکیبی میان چند ویژگی، ممکن است در آزمون‌های تک‌متغیره مرحله قبل به‌طور کامل کشف نشوند. برای این منظور، یک مدل Random Forest به‌صورت اکتشافی (نه به‌عنوان مدل نهایی پروژه) بر روی داده train ران می‌شود، به این دلیل که این مدل بدون نیاز به پیش‌فرض‌های آماری خاص یا استانداردسازی داده، قادر است روابط پیچیده‌تر را نیز شناسایی کند.

بعد از این گام، اهمیت هر متغیر از دو منظر بررسی می‌شود: اول با استفاده از شاخص Impurity-based Importance، و دوم با روش اهمیت مبتنی بر جایگشت^{۱۳} که با به‌هم‌ریختن مقادیر هر ویژگی به‌صورت جداگانه و سنجش میزان افت عملکرد مدل، سنجشی منصفانه‌تر و مستقل از نوع ویژگی (پیوسته یا دسته‌ای) ارائه می‌دهد؛ این روش دوم به‌ویژه برای جبران سوگیری روش نخست نسبت به ویژگی‌های پیوسته یا دارای سطوح بیشتر به‌کار گرفته شده است.

Feature	Importance (impurity-based)
Online boarding	0.1631
Type of Travel_Personal Travel	0.1076
Inflight wifi service	0.1075
Class_Eco	0.0774
Inflight entertainment	0.0586
Seat comfort	0.0544
Flight Distance	0.0447
Leg room service	0.0400

«جدول ۱۳»

مقایسه دو روش سنجش اهمیت ویژگی، یعنی شاخص Impurity-based و اهمیت مبتنی بر جایگشت، نتایج قابل توجهی به همراه داشت. سه ویژگی Type of Travel، Inflight wifi service و Online boarding در

¹³ Permutation Importance

هر دو روش در رتبه‌های بالا قرار گرفتند و به‌عنوان قوی‌ترین و پایدارترین متغیرهای پیش‌بینی‌کننده رضایت مسافر شناخته می‌شوند.

با این حال، در سایر ویژگی‌ها اختلاف چشمگیری بین دو روش مشاهده شد که دقیقاً همان سوگیری روش Impurity-based را تایید می‌کند. برای مثال، ویژگی Flight Distance که پیوسته و دارای مقادیر متنوع است، در روش اول رتبه‌ی نسبتاً بالایی داشت، اما در Permutation Importance تقریباً در انتهای فهرست قرار گرفت؛ این موضوع نشان می‌دهد اهمیت بالای این ستون در روش اول بیشتر ناشی از فرصت بیشتر برای تقسیم‌بندی داده در درخت‌های تصمیم بوده است، نه ارتباط واقعی و قوی با رضایت مسافر. ویژگی Age نیز افت مشابهی نشان داد و از رتبه‌ی نسبتاً بالا در روش اول به رتبه‌ای میانی در Permutation Importance رسید، هرچند برخلاف Flight Distance، در انتهای فهرست قرار نگرفت.

الگوی مشابهی برای Inflight entertainment نیز دیده شد که با وجود رتبه بالا در روش اول، در Permutation Importance اهمیت بسیار کمی نشان داد؛ این کاهش احتمالاً به دلیل همبستگی این ویژگی با ستون‌های قوی‌تری مانند Seat comfort و Cleanliness است، به‌طوری‌که مدل بخش عمده اطلاعات مشترک را از طریق آن ویژگی‌های قوی‌تر دریافت کرده و دیگر نیازی به تکیه زیاد بر Inflight entertainment نداشته است.

در مقابل، ویژگی‌های Departure Delay in Minutes، Arrival Delay in Minutes و Gender در هر دو روش به‌طور پیوسته در پایین‌ترین رتبه‌ها قرار گرفتند، که با نتایج ضعیف این ستون‌ها در آزمون‌های آماری مراحل قبل هم‌راستا است. این نزدیکی نتایج میان چند روش مستقل، اطمینان بیشتری نسبت به بی‌اثر بودن واقعی این ویژگی‌ها فراهم می‌کند و قدرت کم توضیح‌دهندگی آن‌ها را نشان می‌دهد.

به‌طور کلی، این مقایسه نشان می‌دهد که اتکای صرف به یک شاخص می‌تواند منجر به نتیجه‌گیری نادرست درباره اهمیت برخی ویژگی‌های هم‌بسته شود. استفاده هم‌زمان از Permutation Importance، تصویری دقیق‌تر و قابل‌اعتمادتر از نقش واقعی هر ویژگی در پیش‌بینی رضایت مسافران ارائه می‌دهد.

با ترکیب یافته‌های Chi-Square، Mann-Whitney، و هر دو روش اهمیت مدل، این ستون‌ها به‌طور مداوم در پایین‌ترین رتبه‌ها قرار گرفته‌اند و کاندیدهای حذف هستند:

- Gate location
- Gender
- Departure Delay in Minutes
- Arrival Delay in Minutes
- Departure/Arrival time convenient

Feature	Importance (permutation, mean)	Importance (permutation, std)
Type of Travel_Personal Travel	0.1501	0.0020
Inflight wifi service	0.1026	0.0013
Customer Type_disloyal Customer	0.0578	0.0012
Online boarding	0.0355	0.0010
Checkin service	0.0269	0.0010
Gate location	0.0014	0.0007
Departure/Arrival time convenient	0.0007	0.0002
Flight Distance	0.0005	0.0004
Class_Eco Plus	0.0002	0.0001
Arrival Delay in Minutes	-0.0000	0.0005
Gender_Male	-0.0002	0.0004
Food and drink	-0.0003	0.0002
Departure Delay in Minutes	-0.0005	0.0004

«جدول ۱۴»

در نهایت، با وجود اینکه Class_Eco Plus و Food and drink در هر دو روش اهمیت مبتنی بر مدل نمرات پایینی کسب کردند، این دو ویژگی جزو کاندیدهای حذف در نظر گرفته نشدند. در مورد Food and drink، آزمون Mann-Whitney اندازه اثر قابل توجهی برابر با ۰.۲۳۶۶ نشان می‌دهد که حتی از برخی ویژگی‌های باقی‌مانده در لیست نهایی مانند Age نیز بالاتر است؛ بنابراین افت اهمیت آن در مدل Random Forest احتمالاً ناشی از هم‌بستگی با ویژگی‌های قوی‌تری مانند Seat comfort و Cleanliness است، نه بی‌ارتباط

بودن واقعی آن با رضایت مسافر. در مورد Class_Eco Plus نیز باید توجه داشت که این ستون تنها یکی از سطوح رمزگذاری شده (one-hot) متغیر دسته‌ای اصلی Class است، و نتایج آزمون Chi-Square نشان می‌دهد Class با Cramér's V برابر با ۰.۵۰۲۴ قوی‌ترین ارتباط را در میان تمامی متغیرهای دسته‌ای با متغیر هدف دارد؛ از این رو، تصمیم‌گیری درباره حذف باید در سطح کل متغیر Class انجام شود، نه یک سطح مجزا از آن، و با توجه به اهمیت بالای این متغیر در کل، هیچ‌کدام از سطوحش کاندیدای حذف نیستند.

۷.۲. اعمال تمیزکاری روی داده تست

پس از اینکه به صورت کامل از صحت پیش‌پردازش داده اطمینان حاصل شد، تمامی تمیزکاری‌های انجام شده روی داده Train، روی داده Test نیز انجام شد. نکته مورد توجه این است که در فرایند پیش‌پردازش داده‌های تست، رعایت اصولی مانند عدم حذف سطرها و جلوگیری از نشت داده‌ها اهمیت بسیار زیادی دارد، زیرا این داده‌ها نمادی از داده‌های ندیده‌ی دنیای واقعی هستند و باید بازتاب‌دهنده عملکرد واقعی مدل باشند. در اولین گام، فایل داده‌های تست بارگذاری شده و ستون‌های شناسایی و غیرضروری که در داده‌های آموزش حذف شده بودند، از داده‌های تست نیز کنار گذاشته می‌شوند.

برای جایگزینی مقادیر خالی، به جای محاسبه مجدد میانگین روی داده‌های تست، از ضریب محاسبه‌شده از داده‌های Train برای بازسازی تاخیرها استفاده می‌شود.

در مرحله مدیریت داده‌های پرت، از آنجا که هیچ سطری از داده‌های تست نباید حذف شود، تمامی مقادیر خارج از محدوده به حدهای مجاز Clip می‌شوند. بر همین اساس، مقادیر سن در بازه مشخص محدود می‌گردند. مسافت پرواز و میزان تاخیرها نیز به حدهای بالا و پایین به دست آمده از تحلیل‌های داده‌های آموزش محدود شده و مقادیر منفی احتمالی صفر می‌شوند. همچنین امتیازات رتبه‌ای در بازه استاندارد خود قرار می‌گیرند.

پس از یکسان‌سازی فرمت و نوع متغیرها، استانداردسازی ویژگی‌های عددی صرفاً با اعمال پارامترهای آماری یادگرفته‌شده از داده‌های آموزش انجام می‌شود تا مدل بتواند ورودی‌ها را در مقیاس صحیح دریافت کند.

در نهایت، دو نسخه مجزا از داده‌های تست تمیزشده، شامل نسخه اولیه و نسخه استانداردشده، جهت استفاده در الگوریتم‌های مختلف ذخیره می‌گردند.

روند کلی مدلسازی و ارزیابی و تحلیل نتایج

پس از پایان پیش‌پردازش، داده‌ها در سه بخش Train، Evaluation و Final Test استفاده می‌شوند. Train برای آموزش و تنظیم مدل، Evaluation برای مقایسه مدل‌ها و Final Test فقط برای ارزیابی نهایی نگه داشته می‌شود.

برای هر الگوریتم، ابتدا نسخه مناسب داده انتخاب می‌شود:

- مدل‌های حساس به مقیاس مانند Logistic Regression، SVM و KNN با داده‌های اسکیل شده
- مدل‌های درختی مانند Decision Tree، Random Forest و XGBoost با داده‌های اسکیل نشده

سپس هر مدل در دو حالت بررسی می‌شود:

۱. با تمام ویژگی‌ها

۲. بدون ویژگی‌های کاندید حذف

این دو حالت با Cross-Validation روی داده Train مقایسه می‌شوند. معیار اصلی، میانگین F1-score است و در کنار آن پایداری Fold ها، Precision، Recall و ROC-AUC بررسی می‌شود. اگر نسخه بدون کاندیدها بهتر یا تقریباً برابر باشد، نسخه ساده‌تر انتخاب می‌شود؛ اما اگر حذف ویژگی‌ها باعث افت محسوس عملکرد شود، تمام ویژگی‌ها نگه داشته می‌شوند.

بعد از انتخاب بهترین نسخه هر الگوریتم، مدل‌های برنده روی یک مجموعه Evaluation مشترک مقایسه می‌شوند. مدل نهایی بر اساس F1-score، ROC-AUC، تعادل Precision و Recall، Confusion Matrix و اختلاف کم بین نتایج Cross-Validation و Evaluation انتخاب می‌شود.

در پایان، تمام تصمیم‌ها ثابت می‌شوند و مدل منتخب فقط یک‌بار روی Final Test ارزیابی خواهد شد.

با این تفاسیر دو بخش بعدی به این صورت خواهد بود:

- بخش ۳: مدلسازی هر کدام از الگوریتم‌ها و انتخاب مدل برنده با استفاده از معیارها
- بخش ۴: مقایسه بین مدل‌های برنده و ران کردن مدل نهایی روی داده تست

۳. مدل سازی

در این مرحله ۴ مدل بررسی می شود که ویژگی های هر کدام در بخش مربوط به خودشان آورده شده است و هر کدام مزایا و معایبی دارند که در هر مرحله بیان شده است.

۱.۳ مدل Logistic Regression

این مدل یک ترکیب خطی وزن دار از ویژگی ها را محاسبه کرده و آن را از طریق تابع سیگموید^{۱۴} به یک احتمال بین صفر و یک تبدیل می کند. به این دلیل که این مدل از طریق Gradient Descent انجام می شود، ویژگی هایی با دامنه ی مقادیر بزرگ تر می توانند به طور مصنوعی بر فرآیند بهینه سازی مسلط شوند؛ به همین دلیل استفاده از داده ی اسکیل شده لازم است.

۱.۱.۳ ارزیابی با تمام متغیرها

در این مرحله، مدل رگرسیون لجستیک با استفاده از مجموعه داده ای اجرا شده است که تمامی ویژگی ها را در بر می گیرد. برای ارزیابی عملکرد مدل از روش اعتبارسنجی Cross-functional استفاده شده است. در این روش، داده ها به پنج بخش تقریباً مساوی تقسیم شدند و نسبت نمونه های مربوط به هر کلاس در تمام بخش ها تا حد امکان مشابه نسبت موجود در کل داده ها حفظ می شود. در هر مرحله، چهار بخش از داده ها، معادل تقریباً ۸۰ درصد نمونه ها، برای آموزش مدل و بخش باقی مانده، معادل تقریباً ۲۰ درصد نمونه ها، برای ارزیابی آن استفاده می شود. این فرایند پنج بار تکرار می شود، به طوری که هر بخش دقیقاً یک بار نقش مجموعه اعتبارسنجی را ایفا می کند. در هر تکرار، یک مدل جدید رگرسیون لجستیک روی داده های آموزشی برازش شده و سپس برچسب کلاس و احتمال تعلق هر نمونه به کلاس مثبت برای داده های اعتبارسنجی پیش بینی می شود.

در نهایت، معیارهای F1، Accuracy، Precision، Recall و ROC-AUC برای هر Fold محاسبه شده و میانگین و انحراف معیار آن ها به عنوان برآوردی از عملکرد کلی و میزان پایداری مدل گزارش شد.

¹⁴ Sigmoid Function

	F1 Score	Accuracy	Precision	Recall	ROC-AUC
Fold					
1	0.8539	0.8724	0.8671	0.8410	0.9298
2	0.8626	0.8802	0.8771	0.8486	0.9354
3	0.8636	0.8806	0.8748	0.8527	0.9355
4	0.8596	0.8768	0.8686	0.8507	0.9343
5	0.8593	0.8770	0.8712	0.8478	0.9343

«جدول ۱۵»

نتایج نشان داد که مدل با استفاده از تمام ویژگی‌ها، عملکرد مناسب و نسبتاً پایداری دارد. میانگین Accuracy برابر با ۰.۸۷۷۴ بود؛ یعنی مدل به‌طور متوسط حدود ۸۷.۷۴ درصد نمونه‌ها را به‌درستی طبقه‌بندی کرده است. همچنین میانگین F1-score برابر با ۰.۸۵۹۸، Precision برابر با ۰.۸۷۱۸ و Recall برابر با ۰.۸۴۸۲ به دست آمد. پایین بودن انحراف معیار این معیارها نشان می‌دهد که عملکرد مدل در Fold های مختلف تغییر زیادی نداشته و نتایج آن وابستگی شدیدی به یک تقسیم‌بندی خاص از داده‌ها نداشته است.

بالاتر بودن Precision نسبت به Recall نشان می‌دهد که پیش‌بینی‌های مثبت مدل نسبتاً دقیق بوده‌اند، اما مدل هنوز بخشی از نمونه‌های مثبت واقعی را شناسایی نکرده است. به عبارت دیگر، میزان منفی کاذب ممکن است کمی بیشتر از حد مطلوب باشد، به‌ویژه اگر شناسایی تمام موارد مثبت اهمیت زیادی داشته باشد.

از طرف دیگر، میانگین ROC-AUC برابر با ۰.۹۳۳۹ بود که بیانگر قدرت تفکیک بسیار خوب مدل میان دو کلاس است. در مجموع، این مدل از نظر دقت، تعادل بین Precision و Recall، قدرت تفکیک و ثبات بین Fold ها عملکرد مطلوبی داشته است. با این حال، برای مقایسه دقیق با مدل دارای ویژگی‌های کمتر، لازم است هر دو مدل با Fold ها، random state و مراحل پیش‌پردازش یکسان ارزیابی شوند.

	Mean	Std
Metric		
F1 Score	0.8598	0.0038
Accuracy	0.8774	0.0033
Precision	0.8718	0.0042
Recall	0.8482	0.0044
ROC-AUC	0.9339	0.0023

«جدول ۱۶»

در مرحله بعدی با فیچرهای انتخاب شده این مدل سازی انجام می شود تا تفاوت بررسی شود.

۲.۱.۳. ارزیابی بدون مدل های کاندید حذف

در این مرحله، همان مدل رگرسیون لجستیک اجرا شده. با این تفاوت که به جای استفاده از تمام ویژگی ها، فقط ویژگی های منتخب موجود در `dfs_scaled_selected_features` وارد مدل شده اند. همچنین از همان Fold های مرحله قبل استفاده شده است تا مقایسه دو مدل منصفانه باشد و اختلاف نتایج تا حد امکان به حذف ویژگی ها مربوط شود.

	Fold	Accuracy	Precision	Recall	F1 Score	ROC-AUC
0	1	0.8709	0.8648	0.8399	0.8522	0.9284
1	2	0.8787	0.8763	0.8456	0.8607	0.9343
2	3	0.8780	0.8732	0.8478	0.8603	0.9348
3	4	0.8739	0.8658	0.8468	0.8562	0.9330
4	5	0.8754	0.8695	0.8459	0.8575	0.9334

«جدول ۱۷»

نتایج نشان می دهد مدل دارای ویژگی های منتخب همچنان عملکرد مناسب و پایداری دارد. میانگین Accuracy برابر با 0.8754 است؛ یعنی مدل حدود 87.54 درصد نمونه ها را به درستی طبقه بندی کرده است. میانگین Precision، Recall و F1-score نیز به ترتیب 0.8699، 0.8452 و 0.8574 به دست آمده اند. بیشتر بودن Precision نسبت به Recall نشان می دهد مدل در پیش بینی موارد مثبت نسبتاً دقیق تر است، اما بخشی از نمونه های مثبت واقعی را شناسایی نمی کند.

	Metric	Mean	Standard Deviation
0	Accuracy	0.8754	0.0032
1	Precision	0.8699	0.0049
2	Recall	0.8452	0.0031
3	F1 Score	0.8574	0.0035
4	ROC-AUC	0.9327	0.0025

«جدول ۱۸»

۳.۱.۳. انتخاب مدل منتخب

در مقایسه با مدل دارای تمام ویژگی‌ها، عملکرد مدل ویژگی‌های منتخب اندکی کاهش یافته است. با این حال، این اختلاف‌ها بسیار کوچک هستند و نشان می‌دهند حذف بخشی از ویژگی‌ها تاثیر قابل توجهی بر عملکرد مدل نداشته است. بنابراین، مدل دارای ویژگی‌های منتخب با حفظ تقریباً همان دقت پیش‌بینی، ساده‌تر و تفسیرپذیرتر است و می‌تواند انتخاب مناسب‌تری باشد؛ به‌ویژه اگر هدف کاهش تعداد متغیرها و ساخت یک مدل کم‌پیچیدگی‌تر باشد.

۴.۱.۳. Hyperparameters Tuning

بعد از مشخص شدن مدل برنده در رگرسیون لجستیک، در نهایت تنظیم پارامترهای مدل انجام می‌شود. هدف اصلی در این بخش، دستیابی به بهینه‌ترین پارامترها برای الگوریتم رگرسیون لجستیک به منظور پیش‌بینی متغیر هدف با بیشترین قدرت و دقت ممکن است.

برای رسیدن به این هدف، فرایند با استفاده از الگوریتم جستجوی شبکه‌ای به همراه 5-fold Stratified Cross-Validation پیاده‌سازی شد تا نسبت کلاس‌ها در تمام بخش‌ها حفظ شده و ارزیابی عادلانه‌ای صورت گیرد. در فضای جستجوی تعریف‌شده، هایپرپارامترهای کلیدی نظیر ضریب تنظیم C در دامنه ۰.۰۰۱ تا ۱۰۰، نوع L1 و L2 Regularization، الگوریتم‌های حل‌کننده liblinear و saga و همچنین حالت‌های وزن‌دهی None و balanced مورد ارزیابی قرار گرفتند و ROC-AUC به عنوان شاخص اصلی ارزیابی انتخاب گردید.

Category	Parameter / Metric	Value
Hyperparameter	C	0.1
Hyperparameter	Penalty	l1
Hyperparameter	Solver	saga
Hyperparameter	Class Weight	balanced
Performance Metric	Mean Train ROC-AUC	0.9329
Performance Metric	Train ROC-AUC SD	0.0006
Performance Metric	Mean Validation ROC-AUC	0.9328
Performance Metric	Validation ROC-AUC SD	0.0023
Evaluation Metric	Train-Validation Gap	0.0001

«جدول ۱۹»

تحلیل نتایج حاصل از اجرا نشان می‌دهد که بهترین عملکرد زمانی حاصل می‌شود که از ضریب تنظیم C برابر ۰.۱، L1 Regularization، و saga وزن‌دهی balanced استفاده شود. مدل بهینه‌شده موفق گردید به میانگین امتیاز ROC-AUC برابر ۰.۹۳۲۸ روی داده‌های اعتبارسنجی دست یابد که نشان‌دهنده قدرت تفکیک بسیار بالای آن است. مقایسه میانگین امتیاز آموزش برابر ۰.۹۳۲۹ با امتیاز اعتبارسنجی ۰.۹۳۲۸ و اختلاف بسیار ناچیز ۰.۰۰۰۱ میان آن‌ها ثابت می‌کند که مدل به هیچ عنوان دچار بیش‌برازش نشده است. علاوه بر این، انحراف معیار بسیار پایین ثبت‌شده در ارزیابی آموزش با مقدار ۰.۰۰۰۶ و در اعتبارسنجی با مقدار ۰.۰۰۲۳ گواهی بر پایداری و استواری بالای مدل در تمام ۵ بخش اعتبارسنجی دارد. در نهایت، انتخاب L1 همراه با ضریب C برابر ۰.۱ باعث می‌شود مدل ضمن حفظ حداکثر قدرت پیش‌بینی، با کنترل پیچیدگی به قابلیت تفسیرپذیری بهتری دست یابد.

۲.۳. مدل Decision Tree

مدل درخت تصمیم یک الگوریتم یادگیری ماشین مبتنی بر ساختار درختی است که با تقسیم مکرر داده‌ها بر اساس ویژگی‌های مختلف، نمونه‌ها را به گروه‌های کوچک‌تر و نسبتاً همگن تقسیم می‌کند. در هر گره، الگوریتم بهترین ویژگی و نقطه تقسیم را بر اساس معیارهایی مانند Gini Impurity یا Entropy در مسائل طبقه‌بندی انتخاب می‌کند. این فرآیند تا رسیدن به شرایط توقف ادامه یافته و در نهایت هر برگ درخت نشان‌دهنده پیش‌بینی مدل است. سادگی، قابلیت تفسیر بالا و توانایی مدل‌سازی روابط غیرخطی از مزایای اصلی Decision Tree است؛ با این حال، در صورت رشد بیش از حد درخت، احتمال Overfitting افزایش می‌یابد.

۱.۲.۳. ارزیابی با تمام متغیرها

در این مرحله، مدل درخت تصمیم با استفاده از مجموعه داده‌ای اجرا شده است که همه ستون‌ها را در بر می‌گیرد. برای آموزش و ارزیابی عملکرد مدل پایه، رویکرد تقسیم ساده داده‌ها تغییر یافت و از روش Cross-Validation روی کل داده‌ها استفاده گردید. در این روش، داده‌ها به بخش‌های مساوی تقسیم شده و در هر مرحله بخشی از داده‌ها برای آموزش مدل و بخش باقی‌مانده برای ارزیابی آن استفاده می‌شود. این فرایند تکرار می‌شود به‌طوری‌که هر بخش نقش مجموعه اعتبارسنجی را ایفا کند. در هر تکرار، مدل درخت تصمیم با هایپرپارامترهای پیش‌فرض روی داده‌های آموزشی برازش شده و سپس خروجی‌ها پیش‌بینی می‌گردد. در نهایت، معیارهای ارزیابی به صورت جامع از جمله F1-score، Accuracy، Precision و Recall محاسبه شده و میانگین و انحراف معیار آن‌ها استخراج گردید.

	Metric	Mean	Standard Deviation
0	Accuracy	0.9238	0.0007
1	Precision	0.9107	0.0020
2	Recall	0.9181	0.0018
3	F1 Score	0.9144	0.0007
4	ROC-AUC	0.9232	0.0006

«جدول ۲۰»

نتایج حاصل از ارزیابی نشان داد که مدل با استفاده از تمام ویژگی‌ها عملکرد پایه و قابل قبولی را ارائه می‌دهد. (مقادیر دقیق معیارها در هر fold در فایل کد ضمیمه قابل مشاهده است).

۲.۲.۳. ارزیابی بدون مدل‌های کاندید حذف

در این مرحله، همان ساختار خام مدل درخت تصمیم اجرا شد، با این تفاوت که به جای استفاده از تمام ویژگی‌ها، فقط مجموعه داده شامل ستون‌های مهم‌تر، وارد مدل شدند. فرایند Cross-Validation دقیقاً مشابه مرحله قبل روی این داده‌ها نیز پیاده‌سازی شد تا مقایسه دو مجموعه داده کاملاً منصفانه باشد و عملکرد پایه آن‌ها مشخص گردد.

	Metric	Mean	Standard Deviation
0	Accuracy	0.9225	0.0014
1	Precision	0.9091	0.0024
2	Recall	0.9167	0.0033
3	F1 Score	0.9129	0.0016
4	ROC-AUC	0.9219	0.0015

«جدول ۲۱»

۳.۲.۳. انتخاب مدل منتخب

بر اساس خروجی‌های به دست آمده از جداول ارزیابی، مدل پایه در دو سناریوی All Features و Selected Features در شاخص‌های کلیدی با یکدیگر مقایسه شدند. نتایج نشان داد که عملکرد دو مجموعه داده در حالت پیش فرض بسیار نزدیک به یکدیگر است؛ با این حال، بر اساس مقادیر ثبت شده، مجموعه داده All Features برتری خفیفی از خود نشان داد. بنابراین، این مجموعه داده به عنوان داده برتر برای ورود به مرحله بهینه‌سازی و تنظیمات پیشرفته انتخاب شد.

۴.۲.۳. Hyperparameters Tuning

بعد از مشخص شدن مجموعه داده برنده، در نهایت تنظیم پارامترهای مدل انجام می‌شود. هدف اصلی در این بخش، دستیابی به بالاترین میزان دقت و جلوگیری از مشکلاتی مانند بیش‌برازش برای الگوریتم درخت تصمیم است. برای رسیدن به این هدف، بهترین هایپرپارامترها برای مدل انتخاب‌شده با استفاده از الگوریتم جستجوی GridSearch استخراج شد. در این گام، پارامترهای کلیدی نظیر `max_depth`، `min_samples_split`، `min_samples_leaf` و `criterion` مورد بررسی و بهینه‌سازی قرار گرفتند.

	criterion	max_depth	min_samples_leaf	min_samples_split
0	entropy	10	4	10

«جدول ۲۲»

در مرحله پایانی، داده‌های انتخاب‌شده به بخش‌های Train و Test تقسیم شدند و مدل درخت تصمیم با استفاده از بهترین ساختار ابرپارامترهای کشف‌شده در گام قبل، دوباره بر روی داده‌های آموزشی اجرا و برازش شد. نتایج حاصل از ارزیابی مدل بهینه‌شده روی داده‌های آزمون نشان‌دهنده بهبود در تمامی شاخص‌ها بود. در نهایت، مدل نهایی و برگزیده در این بخش درخت تصمیم آموزش‌دیده بر روی تمامی ستون‌ها به همراه هایپرپارامترهای بهینه‌شده می‌باشد.

۳.۳. مدل Random Forest

مدل Random Forest یک الگوریتم یادگیری ماشین مبتنی بر روش Bagging است که با ساخت تعداد زیادی درخت تصمیم و ترکیب نتایج آن‌ها، پیش‌بینی نهایی را انجام می‌دهد. در فرآیند ساخت هر درخت، نمونه‌های مختلفی از داده‌ها و زیرمجموعه‌ای تصادفی از ویژگی‌ها مورد استفاده قرار می‌گیرند؛ این تصادفی‌سازی باعث کاهش وابستگی بین درخت‌ها و کاهش احتمال Overfitting می‌شود. در مسائل طبقه‌بندی، پیش‌بینی نهایی معمولاً بر اساس رای اکثریت درخت‌ها و در مسائل رگرسیون بر اساس میانگین پیش‌بینی درخت‌ها تعیین می‌شود. این مدل به دلیل دقت مناسب، مقاومت در برابر نویز و توانایی مدل‌سازی روابط پیچیده و غیرخطی، یکی از الگوریتم‌های پرکاربرد در مسائل یادگیری ماشین است.

۱.۳.۳. ارزیابی با تمام متغیرها

در این مرحله، مدل جنگل تصادفی با استفاده از مجموعه داده‌ای که همه ستون‌ها را در بر می‌گیرد، اجرا گردید. رویکرد آموزش به جای تقسیم ساده، بر پایه روش Cross-Validation روی کل داده‌ها بنا شد. الگوریتم با

پیمایش این داده‌ها با استفاده از هایپرپارامترهای پیش‌فرض آموزش دید. پس از پایان این مرحله، معیارهای ارزیابی به شکل جامع شامل میانگین و انحراف معیار استخراج شدند.

	Metric	Mean	Standard Deviation
0	Accuracy	0.9492	0.0015
1	Precision	0.9677	0.0012
2	Recall	0.9158	0.0031
3	F1 Score	0.9411	0.0018
4	ROC-AUC	0.9878	0.0004

«جدول ۲۳»

نتایج حاصل از ارزیابی نشان داد که مدل با استفاده از تمام ویژگی‌ها عملکرد پایه و قابل قبولی را ارائه می‌دهد. (مقادیر دقیق معیارها در هر fold در فایل کد ضمیمه قابل مشاهده است).

۲.۳.۳. ارزیابی بدون مدل‌های کاندید حذف

در این مرحله، همان ساختار مدل جنگل تصادفی تنها بر روی داده‌های شامل ستون‌های مهم‌تر اجرا شد.

	Metric	Mean	Standard Deviation
0	Accuracy	0.9494	0.0019
1	Precision	0.9689	0.0009
2	Recall	0.9153	0.0043
3	F1 Score	0.9413	0.0024
4	ROC-AUC	0.9870	0.0004

«جدول ۲۴»

ارزیابی‌ها نشان داد که مدل با استفاده از ویژگی‌های منتخب نیز عملکرد بسیار نزدیکی دارد.

۳.۳.۳. انتخاب مدل منتخب

با مقایسه خروجی‌های به‌دست‌آمده در شاخص‌هایی نظیر Accuracy، F1-Score، Precision و Recall، مشخص گردید که عملکرد هر دو مجموعه داده در حالت پیش‌فرض بسیار نزدیک به یکدیگر است. با این حال، بر اساس مقادیر ثبت‌شده، مجموعه داده All Features برتری بسیار خفیفی داشت و در نتیجه بالاترین کارایی را ارائه داد. از این رو، این مجموعه داده به‌عنوان داده برتر برای ورود به مرحله تنظیمات پیشرفته انتخاب گردید.

۴.۳.۳ Hyperparameters Tuning

به منظور دستیابی به بالاترین میزان دقت و جلوگیری از مشکلاتی نظیر بیش‌برازش در مدل جنگل تصادفی، فرایند بهینه‌سازی هایپرپارامترها اجرا شد. این فرایند با استفاده از GridSearch انجام شد و بهترین تنظیمات برای مدل استخراج گردید.

max_depth	min_samples_leaf	min_samples_split	n_estimators	
0	None	2	5	200

«جدول ۲۵»

در مرحله پایانی، داده‌های انتخاب‌شده به بخش‌های Train و Test تقسیم شدند و مدل Random Forest با استفاده از این بهترین هایپرپارامترهای استخراج‌شده، مجدداً بر روی داده‌های آموزشی اجرا و برازش گردید. نتایج حاصل از ارزیابی مدل بهینه‌شده روی داده‌های آزمون نشان‌دهنده بهبود نسبی در تمامی شاخص‌ها بود در نهایت، مدل برنده و انتخاب‌شده در این بخش، مدل Random Forest آموزش‌دیده با تمامی ستون‌ها به همراه هایپرپارامترهای بهینه‌شده می‌باشد.

۴.۳ مدل XGBoost

چهارمین و آخرین مدل، XGBoost است. Extreme Gradient Boosting یک الگوریتم یادگیری ماشین مبتنی بر روش Gradient Boosting است که با ساخت مجموعه‌ای از درخت‌های تصمیم به صورت تدریجی، خطاهای مدل‌های قبلی را در هر مرحله کاهش می‌دهد. در این روش، هر درخت جدید با استفاده از Gradient و ماتریس Hessian تابع خطا تلاش می‌کند بهترین تقسیم‌بندی را پیدا کرده و پیش‌بینی مدل را بهبود دهد. همچنین XGBoost با استفاده از Regularization، نرخ یادگیری و کنترل پیچیدگی درخت‌ها، از بیش‌برازش جلوگیری کرده و قابلیت تعمیم مدل را افزایش می‌دهد. به دلیل دقت بالا، سرعت مناسب و توانایی مدل‌سازی روابط غیرخطی، XGBoost یکی از الگوریتم‌های پرکاربرد در مسائل طبقه‌بندی و رگرسیون است.

۱.۴.۳ ارزیابی با تمام متغیرها

در این مرحله، مدل با تمام ویژگی‌های موجود روی دیتاست مربوطه اجرا شد.

	Metric	Mean	Std Dev
0	Accuracy	0.9518	0.0013
1	Precision	0.9665	0.0024
2	Recall	0.9232	0.0030
3	F1 Score	0.9444	0.0016
4	ROC-AUC	0.9902	0.0003

«جدول ۲۶»

نتایج حاصل عملکردی نسبتاً خوب و پایداری بالا در تمامی ارزیابی‌ها را نشان می‌دهد. میزان Accuracy مدل برابر با ۹۵.۱۸ درصد است. علاوه بر این، مقدار Precision ۹۶.۶۵ درصد و Recall ۹۲.۳۲ درصد است؛ بالا بودن Precision نسبت به Recall بیانگر آن است که مدل هنگام پیش‌بینی کلاس مثبت بسیار با احتیاط عمل کرده و خطای مثبت کاذب^{۱۵} کمی دارد، در حالی که F1 Score مقدار ۹۴.۴۴ درصد را ثبت کرده و تعادل بسیار مناسبی میان این دو معیار برقرار است.

۲.۴.۳. ارزیابی بدون مدل‌های کاندید حذف

4	Performance Metric	Accuracy	0.9508	0.0012
5	Performance Metric	Precision	0.9680	0.001
6	Performance Metric	Recall	0.9194	0.0028
7	Performance Metric	F1 Score	0.9431	0.0015
8	Performance Metric	ROC-AUC	0.9890	0.0005

«جدول ۲۷»

نتایج مرحله دوم هم نزدیک به مرحله اول است. در این مرحله، معیار Accuracy برابر با ۰.۹۵۰۸ به دست آمده که نشان می‌دهد مدل توانسته بخش زیادی از داده‌ها را به درستی طبقه‌بندی کند. همچنین معیار Precision با عدد ۰.۹۶۸۰ در سطح بالایی قرار دارد و نشان می‌دهد مدل در تشخیص کلاس مثبت خطای کمی دارد، در حالی که Recall برابر با ۰.۹۱۹۴ بوده و تعادل کلی این دو در معیار F1 Score با مقدار ۰.۹۴۳۱ منعکس شده است. معیار ROC-AUC نیز عدد ۰.۹۸۹۰ را ثبت کرده که قدرت تفکیک‌پذیری عالی مدل را

¹⁵ False Positive

نشان می‌دهد. مقادیر Std Dev نیز در تمام متریک‌ها بین ۰.۰۰۰۵ تا ۰.۰۰۲۸ بوده که نشان‌دهنده ثبات بالای مدل است.

۳.۴.۳. انتخاب مدل منتخب

اگرچه مدل با تمامی ویژگی‌ها در اکثر معیارها از جمله Accuracy و ROC-AUC با اختلاف صدم درصدی مقادیر بسیار جزئی بهتری دارد، اما مجموعه داده dfs_unscaled_selected_features با کاهش ابعاد داده‌ها توانسته تقریباً همان سطح از کارایی (اختلاف کمتر از ۰.۱ درصد) را با پیچیدگی کمتری حفظ کند. با این حال، بر اساس معیار عددی محض، dfs_unscaled_all_features بالاترین حد کارایی را کسب کرده است. بنابراین مرحله چهارم با ویژگی‌های منتخب انجام می‌شود و مدل برنده این مدل است.

۴.۴.۳. Hyperparameters Tuning

	Category	Parameter / Metric	Value
0	Best Hyperparameter	subsample	1.0000
1	Best Hyperparameter	n_estimators	200.0000
2	Best Hyperparameter	max_depth	12.0000
3	Best Hyperparameter	learning_rate	0.1000
4	Best Hyperparameter	colsample_bytree	1.0000
5	Cross-Validation	Best CV ROC-AUC	0.9904
6	Validation Performance	Accuracy	0.9500
7	Validation Performance	Precision	0.9654
8	Validation Performance	Recall	0.9192
9	Validation Performance	F1 Score	0.9417
10	Validation Performance	ROC-AUC	0.9902


«جدول ۲۸»

برای این بخش هم فرایند Hyperparameter Tuning مثل سه مدل قبلی به طور کامل انجام شده است. در واقع، مدل نهایی صرفاً با تنظیمات اولیه اجرا نشده، بلکه تمامی هایپراپارامترهای کلیدی آن مانند تعداد درخت‌ها، ساختار تصمیم‌گیری، نرخ یادگیری و نحوه استفاده از ویژگی‌ها بهینه‌سازی شده‌اند تا مدل به بهترین کارایی و بالاترین قدرت تعمیم‌دهی روی داده‌های جدید برسد.

۴. ارزیابی و تحلیل نتایج

۱.۴. مقایسه و انتخاب مدل نهایی

پس از اینکه برای هر مدل، حالت مناسب‌تر مشخص شد، بر اساس معیارهای محاسبه شده بعد از hyperparameter tuning و همچنین confusion matrix، نوبت به مقایسه بین این مدل‌ها می‌رسد تا در نهایت بهترین مدل برای اجرا روی تست انتخاب شود.



«جدول ۲۹»

نتایج نشان داد که مدل Logistic Regression اگرچه کمترین اختلاف بین عملکرد داده‌های train و میانگین عملکرد حاصل از اعتبارسنجی را داشت و از این نظر رفتار بسیار پایداری از خود نشان داد، اما مقدار میانگین ROC-AUC آن به طور محسوسی کمتر از سایر مدل‌ها بود. این موضوع نشان می‌دهد که اگرچه مدل از قابلیت تعمیم مناسبی برخوردار است، اما توانایی آن در شناسایی الگوهای پیچیده موجود در داده‌ها نسبت به سایر مدل‌ها محدودتر بوده است و در نتیجه قدرت تفکیک کلاس‌های مسئله نسبت به سایر مدل‌های مورد بررسی پایین‌تر است. بنابراین، با وجود پایداری مناسب، این مدل گزینه مناسبی برای انتخاب به عنوان مدل نهایی محسوب نمی‌شود.

در مقابل، مقایسه دو مدل Decision Tree و Random Forest نشان می‌دهد که استفاده از روش Ensemble موجب بهبود عملکرد پیش‌بینی شده است، به گونه‌ای که Random Forest میانگین ROC-AUC بالاتری نسبت به Decision Tree کسب کرده است. با این حال، مقدار ROC-AUC برابر با ۱ در داده‌های آموزشی و اختلاف بیشتر بین عملکرد train و میانگین عملکرد حاصل از اعتبارسنجی نشان می‌دهد که این مدل تمایل بیشتری به یادگیری ویژگی‌های خاص داده‌های آموزشی دارد. هرچند این موضوع به تنهایی به معنای overfitting قطعی نیست، اما نسبت به سایر مدل‌ها احتمال کاهش عملکرد روی داده‌های جدید را افزایش می‌دهد. در مقابل، Decision Tree با وجود داشتن ROC-AUC کمی پایین‌تر، اختلاف بسیار کمتری بین عملکرد training و validation نشان داده است که بیانگر تعادل بهتر میان قدرت یادگیری و قابلیت تعمیم مدل است.

در میان تمامی مدل‌های مورد بررسی، XGBoost بهترین عملکرد کلی را ارائه داد. این مدل بالاترین مقدار میانگین ROC-AUC را در فرآیند crossvalidation کسب کرد که نشان‌دهنده توانایی بیشتر آن در تفکیک صحیح نمونه‌های دو کلاس است. علاوه بر این، مقادیر بالای Accuracy، Precision، Recall و F1-Score نشان می‌دهد که برتری XGBoost تنها به یک معیار محدود نبوده و این مدل در تمامی شاخص‌های اصلی ارزیابی عملکرد مطلوبی داشته است. به عبارت دیگر، XGBoost علاوه بر افزایش دقت کلی، توانسته است تعادل مناسبی میان شناسایی صحیح نمونه‌های مثبت و کاهش خطاهای طبقه‌بندی برقرار کند.

از طرف دیگر، اختلاف بین عملکرد داده‌های train و validation در XGBoost اگرچه اندکی بیشتر از Decision Tree است، اما همچنان در محدوده قابل قبول قرار دارد و به طور محسوسی کمتر از Random Forest است. این موضوع نشان می‌دهد که XGBoost ضمن دستیابی به بالاترین قدرت پیش‌بینی، توانسته است قابلیت تعمیم مناسبی را نیز حفظ کند و نسبت به Random Forest کمتر در معرض یادگیری بیش از حد داده‌های آموزشی قرار گیرد. در نتیجه، این مدل توانسته است تعادل مناسبی میان دقت پیش‌بینی و قابلیت تعمیم برقرار کند.

در مجموع، مقایسه نتایج نشان می‌دهد که هیچ‌یک از مدل‌های مورد بررسی به طور هم‌زمان سطح عملکرد، پایداری و قابلیت تعمیم XGBoost را ارائه نکرده‌اند. Logistic Regression اگرچه پایدارترین مدل از نظر اختلاف عملکرد training و اعتبارسنجی بود، اما از نظر قدرت پیش‌بینی ضعیف‌تر عمل کرد. Random Forest عملکرد پیش‌بینی بسیار خوبی داشت، اما اختلاف بیشتر بین عملکرد آموزش و اعتبارسنجی متقابل، احتمال کاهش قابلیت تعمیم آن را افزایش می‌دهد. Decision Tree نیز تعادل مناسبی میان این دو ویژگی برقرار کرده است، اما همچنان از نظر عملکرد کلی پایین‌تر از XGBoost قرار می‌گیرد. بنابراین، با در نظر

گرفتن تمامی معیارهای ارزیابی، مدل XGBoost بهترین توازن میان دقت پیش‌بینی، عملکرد پایدار و قابلیت تعمیم را نشان داده و به همین دلیل به عنوان مدل نهایی برای ارزیابی روی مجموعه داده آزمون انتخاب شد.

۲.۴. اجرای مدل روی داده test

برای اجرای این مرحله، از همان فایل XGBoost که در بخش ۳ ساخته شده بود یک کپی تهیه شد و در ادامه آن، این مدل روی داده تست اجرا شد.


۳.۴. محاسبه معیارها و ارزیابی نتایج

این نتایج از نظر آماری منطقی، پایدار هستند. نکته‌ای که بیش از همه جلب توجه می‌کند این است که عملکرد مدل روی داده‌های تست تقریباً با عملکرد آن در Cross Validation یکسان است؛ این همان چیزی است که انتظار داریم.

	Metric	Value
0	Accuracy	0.9526
1	Precision	0.9688
2	Recall	0.9219
3	F1 Score	0.9447
4	ROC-AUC	0.9907

«جدول ۳۰»

اگر معیارها را مقایسه کنیم، Accuracy در Cross Validation برابر 95.24% و در Test برابر 95.26% است که اختلاف آن تنها 0.02 درصد است. Precision نیز از 96.90% به 96.88% رسیده و Recall از 92.21% به 92.19% کاهش بسیار ناچیزی داشته است. F1-score هم از 94.50% به 94.47% رسیده است. جالب‌تر اینکه ROC-AUC از 0.9902 در Cross Validation به 0.9907 در داده‌های تست افزایش یافته است. این اختلاف‌ها آن‌قدر کوچک هستند که می‌توان گفت عملکرد مدل روی داده‌های دیده‌نشده همان عملکردی است که در مرحله اعتبارسنجی مشاهده شده بود. بنابراین هیچ نشانه‌ای از Overfitting یا Underfitting مشاهده نمی‌شود و مدل قابلیت تعمیم بسیار خوبی دارد.



«جدول ۳۱»

Confusion matrix نیز همین موضوع را تایید می‌کند. حدود 54.80% از کل نمونه‌ها به درستی در کلاس neutral or dissatisfied و 40.47% به درستی در کلاس satisfied طبقه‌بندی شده‌اند. تنها 1.31% از نمونه‌های کلاس اول به اشتباه به کلاس دوم نسبت داده شده‌اند (False Positive) و 3.43% از مشتریان راضی به اشتباه در کلاس neutral or dissatisfied قرار گرفته‌اند (False Negative). این الگو تقریباً با مرحله Cross Validation یکسان است و نشان می‌دهد که مدل رفتار ثابتی روی داده‌های جدید نیز دارد. همان‌طور که از مقادیر Precision و Recall نیز مشخص بود، تعداد False Negative ها اندکی بیشتر از False Positive ها است؛ بنابراین مدل کمی محافظه‌کارانه‌تر عمل می‌کند و گاهی برخی مشتریان راضی را از دست می‌دهد، اما در مقابل پیش‌بینی‌های مثبت آن از دقت بسیار بالایی برخوردار است.

علی‌رغم بالابودن این معیارها، این نتایج مشکوک نیستند. معمولاً زمانی به نتایج شک می‌کنیم که مثلاً Accuracy اعتبارسنجی ۹۵٪ باشد اما Accuracy تست به ۸۵٪ یا برعکس به ۹۹٪ برسد، یا اختلاف زیادی بین Precision و Recall مشاهده شود. در اینجا تقریباً تمام معیارها در مرحله Test و Cross Validation یکدیگر را تایید می‌کنند.

در این پروژه، داده‌های train و test از ابتدا از یکدیگر جدا بودند و تا مرحله نهایی هیچ استفاده از test نشد، بنابراین حالتی وجود ندارد که data leakage اتفاق افتاده باشد. علاوه بر این، در روند تحلیل این احتمال داده شد که قدرت توضیح دهنده‌گی برخی متغیرها برای متغیر هدف بسیار بالاست و به همین دلیل موجب چنین نتایجی شده است بنابراین در یک فایل نوت‌بوک جداگانه که در بخش ۴ موجود است، یک بار نیز با

فیچرهای منتخب این تست انجام شد. نتایج هر دو بخش (all features و selected features) نتایج بسیار نزدیکی به یکدیگر داشتند و اختلاف قابل تاملی میان این دو مشاهده نشد.